

Polycopié de Calcul Différentiel et Optimisation Numérique

L3 MIDO

Cours de M. Bonnet

Retranscrit par Bastien Marbaud & Victor Barbera

Compilé par Arris Bouzouane & Harold Wallaert

18 mai 2026

Table des matières

1 Optimisation Numérique	2
I. Introduction générale à l'optimisation mathématique	2
II. Quelques méthodes numériques	2
III. Vitesses de convergence de suites	4
2 Calcul Différentiel	6
I. Différentielles d'ordre supérieur	6
II. Formules de Taylor pour les fonctions de plusieurs variables	7
III. Optimisation : Analyse théorique	9
IV. Unicité des points de minimum et convexité	12
V. Optimisation et fonctions quadratiques	16
VI. Quelques rappels d'algèbre linéaire	18
VII. Normes sur $\mathbb{R}^d$ et $\mathbb{R}^{d \times d}$	18
VIII. Conditionnement	19
IX. Méthode de descente de gradient	19
X. Méthode de descente de gradient à pas fixe dans le cas quadratique	19
XI. Convergence de la méthode de descente de gradient à pas fixe dans le cas général	21
XII. Optimisation sous contrainte	24
XIII. Retour sur l'équivalence des définitions des sous-variétés	26
XIV. Espace tangent	27
XV. Théorème des extrema liés	29
XVI. Retour à l'optimisation libre numérique	30
XVII. Calcul du pas optimal (cas quadratique)	31
XVIII. Règles d'Armijo et de Wolfe	34
XIX. Théorème de Zoutendijk	35
XX. Méthode du gradient conjugué	36

Optimisation Numérique

I. Introduction générale à l'optimisation mathématique

Étant donné un ensemble X et une fonction $f : X \rightarrow \mathbb{R}$, on cherche à trouver un point de minimum de f ou de maximum. Maximiser f revient à minimiser $-f$.

On distingue :

- **L'optimisation discrète** quand l'ensemble X a une structure discrète (typiquement quand X est un ensemble fini).
- **L'optimisation continue** quand X a une structure continue. Par exemple $X = \mathbb{R}^d$, X est un sous-ensemble de $\mathbb{R}^d$, X est un espace vectoriel de dimension infinie...

Dans ce cours, on prendra le plus souvent $X = \mathbb{R}^d$, parfois $X \subset \mathbb{R}^d$. On peut parler d'optimisation libre dans le premier cas, et d'optimisation sous contrainte dans le second cas.

Le problème d'optimisation mathématique a de nombreuses applications. Par exemple :

- **En physique / ingénierie** : On peut par exemple chercher une configuration x d'un système physique qui minimise une énergie.
- **En économie / finance** : On peut maximiser un profit, une utilité.
- **En statistique / apprentissage machine**.

Définition 1: Minimum local et global

Soit $X \subset \mathbb{R}^d$ et $f : X \rightarrow \mathbb{R}$.

1. On dit qu'un point $x \in X$ est un **point de minimum local** de f s'il existe $\varepsilon > 0$ tel que :

$$\forall y \in X, \quad \|y - x\| \leq \varepsilon \implies f(y) \geq f(x)$$

2. On dit que c'est un **point de minimum global** de f si :

$$\forall y \in X, \quad f(y) \geq f(x)$$

1 Principales questions

Questions d'ordre théorique :

- Existence d'un point de minimum ?
- Unicité du point de minimum ?
- Comment peut-on caractériser les éventuels points de minimum ?

Questions d'ordre numérique :

- Quels algorithmes permettent de calculer un point de minimum ?
- Que peut-on dire sur l'erreur d'approximation ?

II. Quelques méthodes numériques

En général, étant donnée une donnée initiale $x_0 \in X$, les méthodes numériques consistent en la construction par récurrence d'une suite $(x_k)_{k \geq 0}$ d'approximations d'un point de minimum de f .


1 Méthode de descente de gradient à pas fixe

On suppose que $X = \mathbb{R}^d$ et que $f \in \mathcal{C}^1(\mathbb{R}^d)$. La méthode est définie par la relation de récurrence :

$$x_{k+1} = x_k - \tau \nabla f(x_k)$$

où τ est un paramètre de la méthode, appelé le **pas**.

Représentation graphique :



Cas particulier de la dimension 1 ($X = \mathbb{R}$) :

$$x_{k+1} = x_k - \tau f'(x_k)$$

2 Méthode de descente de gradient à pas variable

$$x_{k+1} = x_k - \tau_k \nabla f(x_k)$$

où le pas τ_k peut dépendre de k . Il existe plusieurs règles de calcul possibles pour choisir le pas τ_k .

3 Méthode de Newton

On suppose maintenant que $f \in \mathcal{C}^2(\mathbb{R}^d)$.

Cas de la dimension 1 : On suppose que $f \in \mathcal{C}^2(\mathbb{R})$. L'idée de la méthode est la suivante : si x^* est un point de minimum local de f , alors $f'(x^*) = 0$. Donc on peut appliquer la méthode de Newton à la recherche d'un zéro de la fonction f' :

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

En dimension d :

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1} \nabla f(x_k)$$

où $\nabla^2 f(x_k)$ est une matrice $d \times d$ appelée la **matrice Hessienne** de f au point x_k .

Pour toutes ces méthodes on peut se demander :

- Est-ce que la suite $(x_k)_{k \geq 0}$ converge vers un point de minimum local de f ?
- Quelle est la vitesse de la convergence ?

III. Vitesses de convergence de suites

Il existe plusieurs notions de vitesse de convergence de suites. Pour ce cours, on utilisera les définitions suivantes :

Définition 2: Convergence linéaire

On dit qu'une suite $(x_k)_{k \geq 0}$ converge **linéairement à taux** $\alpha \in]0, 1[$ vers une limite $x^* \in \mathbb{R}^d$ s'il existe une constante $C > 0$ telle que :

$$\forall k, \quad \|x_k - x^*\| \leq C\alpha^k$$

On dit que la suite converge :

- **Linéairement** si elle converge linéairement à un certain taux $\alpha \in]0, 1[$.
- **Super-linéairement** si elle converge linéairement pour tout taux $\alpha \in]0, 1[$.
- **Sous-linéairement** si elle converge linéairement à aucun taux (mais elle converge quand même).

Définition 3: Convergence à l'ordre β

On dit qu'une suite $(x_k)_{k \geq 0}$ converge à l'ordre $\beta > 1$ vers une limite x^* s'il existe $C > 0$ et $\alpha \in (0, 1)$ tels que :

$$\|x_k - x^*\| \leq C\alpha^{\beta^k}$$

Dans le cas particulier $\beta = 2$, on parle de **convergence quadratique**. Par ailleurs, on parle de convergence à l'ordre 1 pour la convergence linéaire, même si la définition précédente ne s'applique pas.

1 Conditions suffisantes

Proposition 1

S'il existe $\alpha \in]0, 1[$ et $k_0 \in \mathbb{N}$ tels que $\forall k \geq k_0, \|x_{k+1} - x^*\| \leq \alpha \|x_k - x^*\|$, alors la suite $(x_k)_{k \geq 0}$ converge linéairement vers x^* .

Preuve :

Par récurrence immédiate, $\|x_k - x^*\| \leq \alpha^{k-k_0} \|x_{k_0} - x^*\|$. En posant $C = \alpha^{-k_0} \|x_{k_0} - x^*\|$, on a bien la convergence linéaire. $\square$

Proposition 2

S'il existe $\alpha \in]0, 1[$ tel que $\forall k, \|x_{k+1} - x_k\| \leq \alpha \|x_k - x_{k-1}\|$, alors la suite $(x_k)_{k \geq 0}$ converge linéairement à taux α vers une limite $x^* \in \mathbb{R}^d$.

Preuve :

On va montrer que $(x_k)_{k \geq 0}$ est une suite de Cauchy. Pour $k \geq 0$ et $p \geq 0$:

$$\|x_{k+p} - x_k\| \leq \sum_{i=0}^{p-1} \|x_{k+i+1} - x_{k+i}\|$$

Par récurrence sur l'hypothèse :

$$\|x_{k+p} - x_k\| \leq \sum_{i=0}^{p-1} \alpha^{k+i} \|x_1 - x_0\| = \|x_1 - x_0\| \alpha^k \sum_{i=0}^{p-1} \alpha^i$$

On utilise la somme de la suite géométrique :

$$\|x_{k+p} - x_k\| \leq \frac{\|x_1 - x_0\|}{1 - \alpha} \alpha^k \xrightarrow{k \rightarrow +\infty} 0$$

Donc la suite $(x_k)_{k \geq 0}$ est de Cauchy dans l'espace complet $\mathbb{R}^d$, elle converge donc vers une limite $x^* \in \mathbb{R}^d$. En passant à la limite lorsque $p \rightarrow +\infty$:

$$\|x_k - x^*\| \leq \frac{\|x_1 - x_0\|}{1 - \alpha} \alpha^k$$

Ce qui prouve que $(x_k)_{k \geq 0}$ converge linéairement à taux α . □

Proposition 3

S'il existe $C > 0, \beta > 1$ et $k_0 \in \mathbb{N}$ tels que $\forall k \geq k_0, \|x_{k+1} - x^*\| \leq C\|x_k - x^*\|^\beta$, et si de plus $C^{1/(\beta-1)}\|x_{k_0} - x^*\| < 1$, alors la suite $(x_k)_{k \geq 0}$ converge à l'ordre β vers $x^* \in \mathbb{R}^d$.

Calcul Différentiel

I. Différentielles d'ordre supérieur

1 Rappels et différentielle d'ordre 1

Soient $X \subset \mathbb{R}^d$ un ouvert et $f : X \rightarrow \mathbb{R}^m$.

- Si f est différentiable en un point x de X , alors sa différentielle $d_x f$ appartient à l'espace $\mathcal{L}(\mathbb{R}^d, \mathbb{R}^m)$ des applications linéaires de $\mathbb{R}^d$ dans $\mathbb{R}^m$.
- Dans le cas $m = 1$, on définit le gradient $\nabla f(x)$ de f au point x comme l'unique vecteur de $\mathbb{R}^d$ satisfaisant :

$$\forall v \in \mathbb{R}^d, \quad \langle v, \nabla f(x) \rangle = d_x f(v)$$

- On dit que $f \in \mathcal{C}^1(X, \mathbb{R}^m)$ si f est différentiable en tout point de X et si l'application $x \mapsto d_x f$ (de X vers $\mathcal{L}(\mathbb{R}^d, \mathbb{R}^m)$) est continue.

2 Différentielle d'ordre 2

Définition 4: Différentielle d'ordre 2

Soit $f \in \mathcal{C}^1(X, \mathbb{R}^m)$. Si l'application $y \mapsto d_y f$ est différentiable en un point $x \in X$, alors on peut considérer sa différentielle au point x , qu'on appelle la **différentielle seconde** (ou différentielle d'ordre 2) de f au point x , notée $d_x^2 f$.

Remarque

- Si elle existe, alors $d_x^2 f \in \mathcal{L}(\mathbb{R}^d, \mathcal{L}(\mathbb{R}^d, \mathbb{R}^m))$.
- On peut identifier l'espace $\mathcal{L}(\mathbb{R}^d, \mathcal{L}(\mathbb{R}^d, \mathbb{R}^m))$ avec l'espace $\mathcal{L}^2(\mathbb{R}^d, \mathbb{R}^m)$ des applications bilinéaires de $\mathbb{R}^d \times \mathbb{R}^d$ à valeurs dans $\mathbb{R}^m$.
- En général, on écrira que $d_x^2 f \in \mathcal{L}^2(\mathbb{R}^d, \mathbb{R}^m)$, et on notera $d_x^2 f(v, w)$ plutôt que $(d_x^2 f(x))(v)(w)$.

On dit que $f \in \mathcal{C}^2(X, \mathbb{R}^m)$ si $f \in \mathcal{C}^1(X, \mathbb{R}^m)$, si $d_x^2 f$ existe en tout point $x \in X$ et si l'application $x \mapsto d_x^2 f$ est continue.

3 Différentielle d'ordre supérieur à 2

De façon similaire, pour tout $k \in \mathbb{N}^*$, on peut définir la différentielle d'ordre k , $d_x^k f$, de f au point x .

Si elle existe, alors $d_x^k f$ appartient à l'espace $\mathcal{L}^k(\mathbb{R}^d, \mathbb{R}^m)$ des applications k -linéaires de $\mathbb{R}^d \times \dots \times \mathbb{R}^d$ à valeurs dans $\mathbb{R}^m$.

On dit que $f \in \mathcal{C}^k(X, \mathbb{R}^m)$ si $d_x^k f$ existe pour tout $x \in X$ et que l'application $x \mapsto d_x^k f$ est continue.

4 Matrice Hessienne

Définition 5: Hessienne

Soit $f : X \rightarrow \mathbb{R}$ une fonction deux fois différentiable en un point x .

Alors la Hessienne $\nabla^2 f(x)$ de f au point x est l'unique matrice de taille $d \times d$ telle que, pour tous vecteurs $v, w \in \mathbb{R}^d$:

$$\langle v, \nabla^2 f(x) w \rangle = d_x^2 f(v, w)$$

C'est la matrice représentant la forme bilinéaire $d_x^2 f$.

5 Règle de calcul pour la différentielle seconde

Proposition 4: Calcul via les dérivées partielles

Soit $f : X \rightarrow \mathbb{R}^m$. La fonction f appartient à $\mathcal{C}^2(X, \mathbb{R}^m)$ si les propriétés suivantes sont vérifiées :

- $\frac{\partial}{\partial x_i} f(x)$ existe pour tout $x \in X$ et $1 \leq i \leq d$.
- $\frac{\partial}{\partial x_i} \frac{\partial}{\partial x_j} f(x)$ existe pour tout $x \in X$ et $1 \leq i, j \leq d$.
- Pour tout $i, j \in \{1, \dots, d\}$, l'application $x \mapsto \frac{\partial^2 f}{\partial x_i \partial x_j}(x)$ est continue.

Alors, pour tous $x \in X$ et $v, w \in \mathbb{R}^d$:

$$d_x^2 f(v, w) = \sum_{i=1}^d \sum_{j=1}^d \frac{\partial^2 f}{\partial x_i \partial x_j}(x) v_i w_j$$

Remarque

- Un résultat similaire est connu pour la différentielle d'ordre 1 ; on montre le résultat pour la différentielle d'ordre 2 en l'appliquant deux fois.
- Notations usuelles : $\frac{\partial^2 f}{\partial x_i^2}(x) = \frac{\partial}{\partial x_i} \frac{\partial f}{\partial x_i}(x)$ et $\frac{\partial^2 f}{\partial x_i \partial x_j}(x) = \frac{\partial}{\partial x_i} \frac{\partial f}{\partial x_j}(x)$.
- Dans le cas de la Hessienne ($m = 1$), on a : $\nabla^2 f(x) = \left(\frac{\partial^2 f}{\partial x_i \partial x_j}(x) \right)_{1 \leq i, j \leq d}$.

II. Formules de Taylor pour les fonctions de plusieurs variables

Les formules de Taylor pour les fonctions à une seule variable s'étendent assez directement au cas des fonctions de plusieurs variables grâce au raisonnement suivant.

1 Idée de preuve

Soit $f : X \rightarrow \mathbb{R}^m$, $x \in X$ et $h \in \mathbb{R}^d$ tels que le segment $[x, x+h] \subset X$.

On peut alors considérer la fonction $g : [0, 1] \rightarrow \mathbb{R}^m$ définie par $g(t) = f(x+th)$.

On va vouloir utiliser les formules de Taylor sur g . On sait que :

- Si $f \in \mathcal{C}^1(X, \mathbb{R}^m)$, alors $g \in \mathcal{C}^1([0, 1], \mathbb{R}^m)$ et pour tout $t \in [0, 1]$: $g'(t) = d_{x+th} f(h)$.
(Dans le cas $m = 1$, $g'(t) = \langle h, \nabla f(x+th) \rangle$).
- Si $f \in \mathcal{C}^2(X, \mathbb{R}^m)$, alors $g \in \mathcal{C}^2([0, 1], \mathbb{R}^m)$ et pour tout $t \in [0, 1]$: $g''(t) = d_{x+th}^2 f(h, h)$.
(Dans le cas $m = 1$, $g''(t) = \langle h, \nabla^2 f(x+th) h \rangle$).
- Plus généralement, si $f \in \mathcal{C}^k(X, \mathbb{R}^m)$, alors $g \in \mathcal{C}^k([0, 1], \mathbb{R}^m)$ et $g^{(k)}(t) = d_{x+th}^k f(h, \dots, h)$.

L'idée de la preuve de ces formules repose sur la règle de calcul avec les dérivées partielles vue précédemment. On généralise ensuite à tout $h \in \mathbb{R}^d$ par mise à l'échelle / rotation. On déduit de ces égalités les formules de Taylor pour f en appliquant les formules à g .

2 Théorèmes de Taylor

Théorème 1: Taylor-Young

Si $f \in \mathcal{C}^k(X, \mathbb{R}^m)$, alors :

$$f(x+h) = f(x) + d_x f(h) + \frac{1}{2} d_x^2 f(h, h) + \cdots + \frac{1}{k!} d_x^k f(h, \dots, h) + o(\|h\|^k)$$

Théorème 2: Taylor-Lagrange

Si $f \in \mathcal{C}^{k+1}(X, \mathbb{R}^m)$, alors pour un certain $\xi \in]x, x+h[$:

$$f(x+h) = \sum_{j=0}^k \frac{1}{j!} d_x^j f(h, \dots, h) + \frac{1}{(k+1)!} d_\xi^{k+1} f(h, \dots, h)$$

Théorème 3: Taylor avec reste intégral

Si $f \in \mathcal{C}^{k+1}(X, \mathbb{R}^m)$, alors :

$$f(x+h) = \sum_{j=0}^k \frac{1}{j!} d_x^j f(h, \dots, h) + \frac{1}{k!} \int_0^1 (1-t)^k d_{x+th}^{k+1} f(h, \dots, h) dt$$

3 Cas particuliers si f est à valeurs dans $\mathbb{R}$

- **Ordre 1** : Si $f \in \mathcal{C}^1(X)$, alors $f(x+h) = f(x) + \langle h, \nabla f(x) \rangle + o(\|h\|)$.
- **Ordre 2 (Young)** : Si $f \in \mathcal{C}^2(X)$, alors :

$$f(x+h) = f(x) + \langle h, \nabla f(x) \rangle + \frac{1}{2} \langle h, \nabla^2 f(x) h \rangle + o(\|h\|^2)$$

- **Ordre 2 (Lagrange)** : Si $f \in \mathcal{C}^2(X)$, il existe $\xi \in]x, x+h[$ tel que :

$$f(x+h) = f(x) + \langle h, \nabla f(x) \rangle + \frac{1}{2} \langle h, \nabla^2 f(\xi) h \rangle$$

4 Théorème de Schwarz

Théorème 4: Théorème de Schwarz

Soit $X \subset \mathbb{R}^d$ un ensemble ouvert et soit $f \in \mathcal{C}^2(X)$. Alors, pour tout $x \in X$ et pour tous $i, j \in \{1, \dots, d\}$:

$$\frac{\partial}{\partial x_i} \frac{\partial}{\partial x_j} f(x) = \frac{\partial}{\partial x_j} \frac{\partial}{\partial x_i} f(x)$$

Preuve :

Soient e_i, e_j les éléments d'indices i et j de la base canonique de $\mathbb{R}^d$. Pour tout h suffisamment petit :

$$f(x + he_i) = f(x) + h \frac{\partial f}{\partial x_i}(x) + \frac{h^2}{2} \frac{\partial^2 f}{\partial x_i^2}(\xi_1) \quad \text{pour un certain } \xi_1 \in [x, x + he_i]$$

De même :

$$f(x + he_i + he_j) = f(x + he_j) + h \frac{\partial f}{\partial x_i}(x + he_j) + \frac{h^2}{2} \frac{\partial^2 f}{\partial x_i^2}(\xi_2)$$

où $\frac{\partial f}{\partial x_i}(x + he_j) = \frac{\partial f}{\partial x_i}(x) + h \frac{\partial}{\partial x_j} \frac{\partial f}{\partial x_i}(\xi_3)$ pour un certain $\xi_3 \in [x, x + he_j]$.

En combinant ces expressions, on remarque que la quantité :

$$\frac{f(x + he_i + he_j) - f(x + he_i) - f(x + he_j) + f(x)}{h^2}$$

tend vers $\frac{\partial}{\partial x_j} \frac{\partial f}{\partial x_i}(x)$ lorsque $h \rightarrow 0$ en utilisant la continuité des dérivées secondes ($f \in \mathcal{C}^2$). Par un raisonnement similaire en inversant les rôles de i et j , on obtient que cette même quantité tend vers $\frac{\partial}{\partial x_i} \frac{\partial f}{\partial x_j}(x)$. Par unicité de la limite, on en déduit :

$$\frac{\partial}{\partial x_i} \frac{\partial}{\partial x_j} f(x) = \frac{\partial}{\partial x_j} \frac{\partial}{\partial x_i} f(x)$$

□

Remarque

Conséquences du théorème :

- Si $f \in \mathcal{C}^2(X)$, alors pour tout $x \in X$, la matrice Hessienne $\nabla^2 f(x)$ est **symétrique**.
- Si $f \in \mathcal{C}^k(X)$, alors l'ordre des dérivations partielles n'importe pas :

$$\frac{\partial}{\partial x_{i_1}} \dots \frac{\partial}{\partial x_{i_k}} f(x) = \frac{\partial}{\partial x_{\sigma(i_1)}} \dots \frac{\partial}{\partial x_{\sigma(i_k)}} f(x)$$

pour toute permutation σ .

III. Optimisation : Analyse théorique

1 Existence de minimiseurs

Théorème 5: Existence sur un compact

Toute fonction continue f définie sur un ensemble compact non vide $X \subset \mathbb{R}^d$ à valeurs dans $\mathbb{R}$ admet un point de minimum global.

Preuve :

Soit $m := \inf_{x \in X} f(x)$. Par définition de l'infimum, il existe une suite $(x_k)_{k \geq 0}$ d'éléments de X telle que $\lim_{k \rightarrow \infty} f(x_k) = m$ (on appelle cela une *suite minimisante*). Comme X est compact, il existe une sous-suite $(x_{k_j})_{j \geq 0}$ qui converge vers un élément $x^* \in X$. Par continuité de f :

$$f(x^*) = \lim_{j \rightarrow \infty} f(x_{k_j}) = m = \inf_{x \in X} f(x)$$

Donc x^* est un point de minimum global de f sur X .

□

1.1 Cas des fonctions définies sur tout $\mathbb{R}^d$

Définition 6: Ensemble de sous-niveau

On appelle ensemble de sous-niveau (ou ensemble de niveau) d'une fonction $f : \mathbb{R}^d \rightarrow \mathbb{R}$ tout

ensemble de la forme :

$$\{x \in \mathbb{R}^d \mid f(x) \leq M\}$$

pour un certain $M \in \mathbb{R}$.

Définition 7: Coercivité

On dit qu'une fonction $f : \mathbb{R}^d \rightarrow \mathbb{R}$ est **coercive** si tous ses ensembles de sous-niveau sont bornés.

Remarque

- Si $f : \mathbb{R}^d \rightarrow \mathbb{R}$ est continue, alors tous ses ensembles de sous-niveau sont fermés.
- Par conséquent, si f est continue et coercive, tous ses ensembles de sous-niveau sont **compacts**.
- Une fonction f est coercive si et seulement si pour toute suite $(\|x_k\|) \rightarrow +\infty$, on a $f(x_k) \rightarrow +\infty$. On écrit souvent $\lim_{\|x\| \rightarrow +\infty} f(x) = +\infty$.

Théorème 6: Existence pour une fonction coercive

Toute fonction $f : \mathbb{R}^d \rightarrow \mathbb{R}$ continue et coercive admet un point de minimum global sur $\mathbb{R}^d$.

Preuve :

Soit $x_0 \in \mathbb{R}^d$. On peut considérer l'ensemble de sous-niveau $K := \{x \in \mathbb{R}^d \mid f(x) \leq f(x_0)\}$. Comme f est continue et coercive, K est compact. D'après le théorème précédent sur les compacts, f admet un point de minimum global x^* sur K . Pour tout $x \notin K$, $f(x) > f(x_0) \geq f(x^*)$. Ainsi, x^* est aussi un point de minimum global de f sur tout $\mathbb{R}^d$. $\square$

Remarque

La coercivité n'est pas une condition nécessaire pour l'existence d'un minimum (exemple : une fonction constante).

2 Identification et caractérisation des points de minimum

2.1 Condition d'optimalité d'ordre 1 (Critère de Fermat)

Proposition 5: Critère de Fermat

Soit $X \subset \mathbb{R}^d$ un ensemble ouvert. Si $f : X \rightarrow \mathbb{R}$ admet un point de minimum local en x et est différentiable en x , alors :

$$\nabla f(x) = 0$$

Preuve :

On utilise le développement limité $f(x+h) = f(x) + \langle h, \nabla f(x) \rangle + o(\|h\|)$. Supposons que $\nabla f(x) \neq 0$. Alors, pour $h > 0$ petit, en prenant $k = -h\nabla f(x)$, on a :

$$f(x - h\nabla f(x)) = f(x) - h\|\nabla f(x)\|^2 + o(h)$$

Pour h assez petit, $f(x - h\nabla f(x)) < f(x)$, ce qui contredit le fait que x soit un minimum local. $\square$

Définition 8: Point critique

Tout point $x \in X$ tel que $\nabla f(x) = 0$ est appelé un **point critique** de f .

Remarque

Tout point de minimum local ou de maximum local est un point critique. Cependant, il existe des points critiques qui ne sont ni des minima, ni des maxima (ex : points cols).

2.2 Conditions d'optimalité d'ordre deux

Proposition 6: Condition nécessaire d'ordre 2

Soit $X \subset \mathbb{R}^d$ un ouvert. Si $f : X \rightarrow \mathbb{R}$ admet un point de minimum local x et est deux fois différentiable en x , alors $\nabla^2 f(x)$ est **semi-définie positive**.

Preuve :

Supposons que $\nabla^2 f(x)$ ne soit pas semi-définie positive. Alors il existe $v \in \mathbb{R}^d$ tel que $\langle v, \nabla^2 f(x)v \rangle < 0$. Pour $h > 0$ petit, d'après Taylor-Young :

$$f(x + hv) = f(x) + h\langle v, \nabla f(x) \rangle + \frac{h^2}{2}\langle v, \nabla^2 f(x)v \rangle + o(h^2)$$

Comme $\nabla f(x) = 0$ (Fermat), il reste :

$$f(x + hv) = f(x) + \frac{h^2}{2}\langle v, \nabla^2 f(x)v \rangle + o(h^2)$$

Puisque $\langle v, \nabla^2 f(x)v \rangle < 0$, pour h assez petit, $f(x + hv) < f(x)$, donc x n'est pas un minimum local. $\square$

Proposition 7: Condition suffisante d'ordre 2

Soit $X \subset \mathbb{R}^d$ ouvert. Si $f : X \rightarrow \mathbb{R}$ est deux fois différentiable en x avec $\nabla f(x) = 0$ et $\nabla^2 f(x)$ **définie positive**, alors x est un point de minimum local de f .

Preuve :

Comme $\nabla^2 f(x)$ est définie positive, il existe $\varepsilon > 0$ tel que $\langle v, \nabla^2 f(x)v \rangle \geq \varepsilon\|v\|^2$ pour tout v . Le développement de Taylor-Young donne :

$$f(x + h) = f(x) + 0 + \frac{1}{2}\langle h, \nabla^2 f(x)h \rangle + o(\|h\|^2)$$

$$f(x + h) \geq f(x) + \frac{\varepsilon}{2}\|h\|^2 + o(\|h\|^2)$$

Pour $\|h\|$ assez petit, $\frac{\varepsilon}{2}\|h\|^2 + o(\|h\|^2) > 0$, donc $f(x + h) > f(x)$, ce qui prouve que x est un minimum local. $\square$

Remarque

Méthode pour trouver les points de minimum local d'une fonction :

1. Trouver les points critiques ($\nabla f(x) = 0$).
2. Étudier la condition d'optimalité d'ordre 2 (signe des valeurs propres de la Hessienne).

3 Rappels : Critère de Sylvester

Remarque

- Une matrice symétrique M est **définie positive** si et seulement si tous ses mineurs principaux dominants sont strictement positifs.
- Une matrice symétrique est **semi-définie positive** si et seulement si tous ses mineurs principaux sont positifs ou nuls.
- **Critère pour les matrices 2×2** : Une matrice symétrique $M = \begin{pmatrix} a & b \\ b & c \end{pmatrix}$ est semi-définie positive si et seulement si $\det(M) \geq 0$ et $\text{Tr}(M) \geq 0$. Elle est définie positive si $\det(M) > 0$ et $\text{Tr}(M) > 0$.

IV. Unicité des points de minimum et convexité

Définition 9: Ensemble convexe

Un ensemble $X \subset \mathbb{R}^d$ est **convexe** si pour tous points $x, y \in X$ et pour tout $t \in [0, 1]$, le point $(1 - t)x + ty$ appartient à X .

Définition 10: Fonction convexe

Soit $X \subset \mathbb{R}^d$ un ensemble convexe. Une fonction $f : X \rightarrow \mathbb{R}$ est **convexe** si, pour tous $x, y \in X$ et pour tout $t \in [0, 1]$:

$$f((1 - t)x + ty) \leq (1 - t)f(x) + tf(y)$$

Elle est **strictement convexe** si, pour tous $x \neq y$ dans X et tout $t \in]0, 1[$:

$$f((1 - t)x + ty) < (1 - t)f(x) + tf(y)$$

Remarque

Interprétation graphique : Le graphe de la fonction doit être en dessous de ses cordes (strictement en dessous pour la stricte convexité).

Proposition 8: Minimum local et global

Tout point de minimum local d'une fonction convexe est un point de minimum global.

Preuve :

Soit X convexe et $f : X \rightarrow \mathbb{R}$ convexe. Soit x^* un point de minimum local de f .

Supposons qu'il existe $y \in X$ tel que $f(y) < f(x^*)$. Alors pour tout $t \in]0, 1[$:

$$f((1 - t)x^* + ty) \leq (1 - t)f(x^*) + tf(y) < (1 - t)f(x^*) + tf(x^*) = f(x^*)$$

Mais le point $(1 - t)x^* + ty$ est arbitrairement proche de x^* pour t proche de 0, ce qui contredit le fait que x^* soit un point de minimum local. $\square$

Proposition 9: Unicité du minimum

Une fonction strictement convexe admet au plus un point de minimum global.

Preuve :

S'il existait deux points de minimum global x et y distincts, alors $f(x) = f(y) = m$. Par stricte convexité, pour $t = 1/2$, on aurait :

$$f\left(\frac{1}{2}x + \frac{1}{2}y\right) < \frac{1}{2}f(x) + \frac{1}{2}f(y) = m$$

ce qui contredit la définition du minimum global m . □

Remarque

- Une fonction peut être strictement convexe et n'admettre aucun point de minimum (exemple : $x \mapsto e^x$).
- Une fonction convexe (mais pas strictement) peut admettre plusieurs points de minimum, mais l'ensemble de ses points de minimum est alors lui-même un ensemble convexe.

1 Caractérisations différentielles de la convexité**Proposition 10: Caractérisation d'ordre 1**

Soit $X \subset \mathbb{R}^d$ un ouvert convexe et $f \in \mathcal{C}^1(X)$. Les propriétés suivantes sont équivalentes :

1. f est convexe.
2. $\forall x, y \in X, \quad f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$.
3. $\forall x, y \in X, \quad \langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 0$.

Remarque

- Le point (2) signifie que le graphe de f est au-dessus de ses plans tangents.
- Le point (3) est une condition de **monotonie**. Dans le cas $d = 1$ ($X = \mathbb{R}$), cela revient à dire que f' est croissante.

Proposition 11: Caractérisation d'ordre 2

Soit $X \subset \mathbb{R}^d$ un ouvert convexe et $f \in \mathcal{C}^2(X)$.

- f est convexe si et seulement si pour tout $x \in X$, $\nabla^2 f(x)$ est semi-définie positive.
- Si pour tout $x \in X$, $\nabla^2 f(x)$ est définie positive, alors f est strictement convexe. (La réciproque est fautive, ex : $x \mapsto x^4$).

Idée des preuves**Caractérisation d'ordre 1 (cas de la convexité non stricte)**

(ii) $\implies$ (i) :

On suppose que pour tous $x, y \in X$, $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$.

Soient $t \in [0, 1]$ et $z := (1 - t)x + ty$.

On veut montrer que $f(z) \leq (1 - t)f(x) + tf(y)$.

D'après l'hypothèse (ii) appliquée au point z :

- $f(x) \geq f(z) + \langle \nabla f(z), x - z \rangle$
- $f(y) \geq f(z) + \langle \nabla f(z), y - z \rangle$

Or, on a les relations suivantes :

$$x - z = x - ((1 - t)x + ty) = t(x - y)$$

$$y - z = y - ((1 - t)x + ty) = -(1 - t)(x - y)$$

En multipliant la première inégalité par $(1 - t)$ et la deuxième par t :

- $(1 - t)f(x) \geq (1 - t)f(z) + t(1 - t)\langle \nabla f(z), x - y \rangle$
- $tf(y) \geq tf(z) - t(1 - t)\langle \nabla f(z), x - y \rangle$

En sommant ces deux lignes, les termes avec le produit scalaire s'annulent, et on obtient :

$$(1 - t)f(x) + tf(y) \geq (1 - t)f(z) + tf(z)$$

Soit finalement :

$$f(z) \leq (1 - t)f(x) + tf(y)$$

(i) $\implies$ (ii) :

En utilisant la définition de la convexité, on montre que la fonction :

$$\phi : t \in]0, 1] \mapsto \frac{f(x + t(y - x)) - f(x)}{t}$$

est croissante.

En particulier, pour tout $t \in]0, 1]$, on a $\phi(t) \leq \phi(1)$, ce qui donne :

$$\frac{f(x + t(y - x)) - f(x)}{t} \leq f(y) - f(x)$$

En passant à la limite lorsque $t \rightarrow 0^+$, par définition de la différentiabilité, on trouve :

$$d_x f(y - x) \leq f(y) - f(x)$$

D'où :

$$\langle \nabla f(x), y - x \rangle \leq f(y) - f(x)$$

(iii) $\implies$ (ii) :

Soit $g : [0, 1] \rightarrow \mathbb{R}$ définie par $g(t) = f(x + t(y - x))$.

Sa dérivée est donnée par : $g'(t) = \langle \nabla f(x + t(y - x)), y - x \rangle$.

Par hypothèse (iii), la fonction g' est croissante.

Pour $t_2 > t_1$, on a $g'(t_2) - g'(t_1) \geq 0$, ce qui s'écrit :

$$\langle \nabla f(x + t_2(y - x)) - \nabla f(x + t_1(y - x)), y - x \rangle \geq 0$$

En utilisant le théorème des accroissements finis sur g , on montre que :

$$g(1) - g(0) = \int_0^1 g'(t) dt \geq g'(0)$$

Soit :

$$f(y) - f(x) \geq \langle \nabla f(x), y - x \rangle$$

Fin des preuves des caractérisations différentielles

(iii) $\implies$ (ii) :

On suppose que $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$ pour tous $x, y \in X$.

On veut montrer que $f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle$.

D'après le théorème de Taylor-Lagrange, il existe $\xi \in]x, y[$ tel que :

$$\begin{aligned} f(x) &= f(y) + \langle \nabla f(\xi), x - y \rangle \\ f(x) &= f(y) + \frac{\|x - y\|}{\|\xi - y\|} \langle \nabla f(\xi), \xi - y \rangle \end{aligned}$$

Par l'hypothèse (iii) entre ξ et y , on a $\langle \nabla f(\xi) - \nabla f(y), \xi - y \rangle \geq 0$.
On en déduit : $\langle \nabla f(\xi), \xi - y \rangle \geq \langle \nabla f(y), \xi - y \rangle$.

En réinjectant dans l'expression de $f(x)$, on obtient :

$$f(x) \geq f(y) + \frac{\|x - y\|}{\|\xi - y\|} \langle \nabla f(y), \xi - y \rangle$$

Soit finalement :

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle$$

Le raisonnement est identique pour le cas strict.

(ii) $\implies$ (iii) :

Pour tous $x, y \in X$:

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle = \langle \nabla f(x), x - y \rangle - \langle \nabla f(y), x - y \rangle$$

En utilisant (ii) deux fois ($f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$ et inversement) :

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq (f(x) - f(y)) + (f(y) - f(x)) = 0.$$

Caractérisation d'ordre 2

Sens ($\Leftarrow$) :

Supposons que $\nabla^2 f(x)$ soit semi-définie positive pour tout $x \in X$.

D'après Taylor-Lagrange, il existe $\xi \in]x, y[$ tel que :

$$\langle \nabla f(y) - \nabla f(x), y - x \rangle = \langle \nabla^2 f(\xi)(y - x), y - x \rangle \geq 0.$$

Par la caractérisation d'ordre 1, f est convexe.

Réciproque ($\Rightarrow$) :

Si f est convexe, alors pour tout $x \in X$ et $v \in \mathbb{R}^d$:

$$\langle v, \nabla^2 f(x)v \rangle = \lim_{t \rightarrow 0} \frac{\langle v, \nabla f(x + tv) - \nabla f(x) \rangle}{t} = \lim_{t \rightarrow 0} \frac{\langle tv, \nabla f(x + tv) - \nabla f(x) \rangle}{t^2}$$

Le numérateur étant ≥ 0 par l'ordre 1, la limite est ≥ 0 , donc la Hessienne est semi-définie positive.

Remarque

Si on suppose f strictement convexe, on ne peut pas montrer que $\nabla^2 f(x)$ est définie positive.

Exemple 1:

Dans le cas $X = \mathbb{R}$, la condition (iii) revient à dire que f' est croissante (ou strictement croissante).
On a $\nabla^2 f(x) = (f''(x))$ pour tout x .
On peut avoir f' strictement croissante sans avoir $f''(x) > 0$ pour tout x .

V. Optimisation et fonctions quadratiques

Proposition 12: Minimum et point critique

Soit X ouvert convexe et $f \in \mathcal{C}^1(X)$ convexe.
 x est un point de minimum de f ssi $\nabla f(x) = 0$.

Preuve :

Si $\nabla f(x) = 0$, alors pour tout $y \in X : f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle = f(x)$.
Donc x est un point de minimum. □

Remarque

Si on suppose f strictement convexe, on ne peut pas montrer que $\nabla^2 f(x)$ est définie positive.

Exemple 2:

Dans le cas $X = \mathbb{R}$, la condition (iii) revient à dire que f' est croissante (ou strictement croissante).
On a $\nabla^2 f(x) = (f''(x))$ pour tout x .
On peut avoir f' strictement croissante sans avoir $f''(x) > 0$ pour tout x .

Proposition 13: Lien entre point critique et minimum

Soit $X \subset \mathbb{R}^d$ ouvert et convexe. Soit $f \in \mathcal{C}^1(X)$ une fonction convexe.
 $x \in X$ est un point de minimum de f si et seulement si c'est un point critique de f ($\nabla f(x) = 0$).

Preuve :

On sait déjà que si x est un point de minimum, alors c'est un point critique.
Réciproquement, si x est un point critique, alors pour tout $y \in X$:

$$f(y) \geq f(x) + \underbrace{\langle \nabla f(x), y - x \rangle}_{=0} \geq f(x)$$

donc x est un point de minimum. □

Exemple important : fonction quadratique

Définition 11: Fonction quadratique

On dit qu'une fonction $f : \mathbb{R}^d \rightarrow \mathbb{R}$ est quadratique s'il existe $A \in \mathbb{R}^{d \times d}$ symétrique, $b \in \mathbb{R}^d$ et $c \in \mathbb{R}$ tels que :

$$f(x) = \langle x, Ax \rangle + \langle b, x \rangle + c \quad \forall x \in \mathbb{R}^d$$

Remarque

Si $f(x) = \langle x, Bx \rangle + \langle b, x \rangle + c$ avec B non symétrique, alors on a aussi $f(x) = \langle x, Ax \rangle + \langle b, x \rangle + c$ avec $A = \frac{1}{2}B + \frac{1}{2}B^T$ (et donc A symétrique).

On peut remarquer que minimiser $x \mapsto \langle x, Ax \rangle + \langle b, x \rangle + c$ est équivalent à minimiser $x \mapsto \langle x, Ax \rangle + \langle b, x \rangle$.

Dans la suite, on considérera plutôt (de façon équivalente) des fonctions de la forme :

$$x \mapsto \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle \quad \text{avec } A \in \mathbb{R}^{d \times d} \text{ symétrique et } b \in \mathbb{R}^d$$

Soient $A \in \mathbb{R}^{d \times d}$ symétrique et $b \in \mathbb{R}^d$. On considère la fonction $f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle$. Alors on a, pour tout $x \in \mathbb{R}^d$:

- $\nabla f(x) = Ax - b$ (Voir TD)
- $\nabla^2 f(x) = A$

D'où :

- f est convexe si A est semi-définie positive.
- f est strictement convexe si A est définie positive.
(caractérisation différentielle de la convexité : si A est semi-définie positive, il existe $v \in \mathbb{R}^d \setminus \{0\}$ tel que $Av = 0$ et on peut montrer que, $\forall x \in \mathbb{R}^d$, $\frac{1}{2}f(x+v) + \frac{1}{2}f(x) = f(\frac{1}{2}x + \frac{1}{2}(x+v))$, donc f n'est pas strictement convexe).
- $x \in \mathbb{R}^d$ est un point critique de f ssi $Ax = b$.

On s'intéresse principalement au cas où A est définie positive. Dans ce cas, on a :

- L'unique solution de $Ax = b$ est l'unique point de minimum (local et global) de f .
- f est coercive.

Preuve de la coercivité :

$$\begin{aligned} f(x) &= \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle \\ &\geq \frac{1}{2} \lambda_1(A) \|x\|^2 - \langle b, x \rangle \quad (\text{où } \lambda_1(A) \text{ est la plus petite valeur propre de } A) \\ &\geq \frac{1}{2} \lambda_1(A) \|x\|^2 - \|b\| \|x\| \xrightarrow{\|x\| \rightarrow +\infty} +\infty \end{aligned}$$

□

On a utilisé la propriété suivante :

Proposition 14: Propriété de comparaison

Soient $f, g : \mathbb{R}^d \rightarrow \mathbb{R}$. Si f est coercive et $g(x) \geq f(x)$ pour tout $x \in \mathbb{R}^d$, alors g est coercive.

Méthodes numériques pour la minimisation de fonctions quadratiques

On peut appliquer une méthode de descente pour la minimisation de f .

- **Gradient à pas fixe** : $x_{k+1} = x_k - \tau \nabla f(x_k) = x_k - \tau(Ax_k - b)$.
- **Gradient à pas variable** : $x_{k+1} = x_k - \tau_k \nabla f(x_k) = x_k - \tau_k(Ax_k - b)$.

Remarque

Méthode de Newton : La méthode s'écrit

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1} \nabla f(x_k)$$

$$x_{k+1} = x_k - A^{-1}(Ax_k - b) = A^{-1}b$$

qui est le point de minimum de f .

Donc la méthode de Newton converge en une seule itération mais elle implique de calculer A^{-1} : la méthode n'a pas d'intérêt dans ce cas.

VI. Quelques rappels d'algèbre linéaire

Soit $A \in \mathbb{R}^{d \times d}$ une matrice symétrique. Alors elle est diagonalisable dans une base orthonormée.

- Ses valeurs propres sont réelles. On les note $\lambda_1(A) \leq \lambda_2(A) \leq \dots \leq \lambda_d(A)$.
- Il existe une matrice $Q \in \mathcal{O}(d)$ telle que $A = QDQ^T$ avec $D = \text{diag}(\lambda_1(A), \dots, \lambda_d(A))$.
- En d'autres termes, il existe une base orthonormée $(v_1, \dots, v_d)$ de $\mathbb{R}^d$ composée de vecteurs propres de A (il suffit de choisir les vecteurs colonnes de Q).

VII. Normes sur $\mathbb{R}^d$ et $\mathbb{R}^{d \times d}$

1 Normes sur $\mathbb{R}^d$

On rappelle que pour $1 \leq p < +\infty$, on définit la norme :

$$\|x\|_p := \left(\sum_{i=1}^d |x_i|^p \right)^{1/p}$$

Pour $p = +\infty$, on a : $\|x\|_\infty = \max_{1 \leq i \leq d} |x_i|$.

2 Normes sur $\mathbb{R}^{d \times d}$

Pour $1 \leq p \leq +\infty$, on peut définir la norme sur $\mathbb{R}^{d \times d}$ par l'une des trois définitions équivalentes suivantes :

- $\|A\|_p := \sup_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p}$
- $\|A\|_p := \sup_{\|x\|_p=1} \|Ax\|_p$
- $\|A\|_p := \sup_{\|x\|_p \leq 1} \|Ax\|_p$

On dit que $\|\cdot\|_p$ sur $\mathbb{R}^{d \times d}$ est la **norme subordonnée** (ou norme d'opérateur) associée à la norme $\|\cdot\|_p$ sur $\mathbb{R}^d$.

On notera $\|\cdot\|$ la norme $\|\cdot\|_2$ que ce soit sur $\mathbb{R}^d$ ou sur $\mathbb{R}^{d \times d}$.

Les normes $\|\cdot\|_p$ sur $\mathbb{R}^{d \times d}$ sont des **normes matricielles**, ce qui signifie que pour toutes matrices $A, B \in \mathbb{R}^{d \times d}$:

$$\|AB\|_p \leq \|A\|_p \cdot \|B\|_p$$

Proposition 15: Cas de la norme 2

Si $A \in \mathbb{R}^{d \times d}$ est symétrique, alors :

$$\|A\|_2 = \max_{1 \leq i \leq d} |\lambda_i(A)|$$

Preuve en TD!

VIII. Conditionnement

Pour $A \in \mathbb{R}^{d \times d}$ et $1 \leq p \leq +\infty$, on définit :

$$\text{Cond}_p(A) = \|A\|_p \cdot \|A^{-1}\|_p$$

On a toujours $\text{Cond}_p(A) \geq 1$.

Proposition 16: Cas symétrique définie positive

Dans le cas particulier où A est symétrique définie positive, son conditionnement pour la norme 2 est :

$$\text{Cond}_2(A) = \frac{\lambda_d(A)}{\lambda_1(A)}$$

- La plus petite valeur propre est caractérisée par : $\lambda_1(A) = \inf_{\|x\|=1} \langle x, Ax \rangle$.
- La plus grande valeur propre est caractérisée par : $\lambda_d(A) = \sup_{\|x\|=1} \langle x, Ax \rangle$.
- On a également : $\max\{|\lambda_d(A)|, |\lambda_1(A)|\} = \max_{1 \leq i \leq d} |\lambda_i(A)|$.

IX. Méthode de descente de gradient

1 Définitions et interprétation

- **Pas fixe** : $x_{k+1} = x_k - \tau \nabla f(x_k)$ pour un certain $\tau > 0$ (le pas de la méthode).
- **Pas variable** : $x_{k+1} = x_k - \tau_k \nabla f(x_k)$ avec $\tau_k > 0$ qui dépend de k .
- Il existe d'autres variantes.

Interprétation : On suit la direction de plus forte pente. Si on écrit Taylor pour tout $v \in \mathbb{R}^d$: $f(x_k + v) = f(x_k) + \langle v, \nabla f(x_k) \rangle + o(\|v\|^2)$. On cherche la direction $v \in \mathbb{R}^d, \|v\| = 1$ qui minimise $\langle v, \nabla f(x_k) \rangle$. Il s'agit de $v = -\frac{\nabla f(x_k)}{\|\nabla f(x_k)\|}$. Avec la méthode de descente de gradient à pas fixe, on se déplace à chaque itération dans cette direction d'une distance $\tau \|\nabla f(x_k)\|$.

Interprétation géométrique : Sous certaines hypothèses sur f , le gradient de f est orthogonal à ses lignes de niveau. (Si v est un vecteur tangent à la ligne de niveau, alors $\langle v, \nabla f(x) \rangle = 0$). On rappelle qu'on avait défini les ensembles de sous-niveau $\{x \in \mathbb{R}^d \mid f(x) \leq C\}$ pour un certain $C \in \mathbb{R}$. De la même façon, on peut définir les lignes de niveau $\{x \in \mathbb{R}^d \mid f(x) = C\}$.

X. Méthode de descente de gradient à pas fixe dans le cas quadratique

Soient $A \in \mathbb{R}^{d \times d}$ symétrique définie positive et $b \in \mathbb{R}^d$. On considère la fonction quadratique :

$$f : x \mapsto \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle$$

On a vu la semaine dernière que f est strictement convexe, coercive, et admet l'unique point de minimum global $x^* = A^{-1}b$.

1 Représentation graphique

On peut diagonaliser A : $A = QDQ^T$ avec $Q \in SO(d)$ et $D = \text{diag}(\lambda_1(A), \dots, \lambda_d(A))$ où $\lambda_d(A) \geq \dots \geq \lambda_1(A) > 0$ sont les valeurs propres de A .


Alors :

$$\begin{aligned}
 f(x) &= \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle \\
 &= \frac{1}{2} \langle x - x^*, A(x - x^*) \rangle - \frac{1}{2} \langle x^*, Ax^* \rangle \\
 &= \frac{1}{2} \langle x - x^*, QDQ^T(x - x^*) \rangle - \frac{1}{2} \langle x^*, Ax^* \rangle \\
 &= \frac{1}{2} \langle Q^T(x - x^*), DQ^T(x - x^*) \rangle - \frac{1}{2} \langle x^*, Ax^* \rangle
 \end{aligned}$$

Donc, pour tout $C \in \mathbb{R}$:

$$\begin{aligned}
 \{x \in \mathbb{R}^d \mid f(x) = C\} &= \left\{ x \in \mathbb{R}^d \mid \frac{1}{2} \langle Q^T(x - x^*), DQ^T(x - x^*) \rangle = C + \frac{1}{2} \langle x^*, Ax^* \rangle \right\} \\
 &= \left\{ x^* + Qy \mid y \in \mathbb{R}^d, \frac{1}{2} \langle y, Dy \rangle = C + \frac{1}{2} \langle x^*, Ax^* \rangle \right\}
 \end{aligned}$$

Dans le cas de la dimension $d = 2$, ces lignes de niveau sont des ellipses.



Quelque comportement possible pour la méthode de descente de gradient à pas fixe : Rappel : pour A symétrique définie positive, on a $\text{cond}(A) := \frac{\lambda_d(A)}{\lambda_1(A)}$. Plus $\text{cond}(A)$ est grand, plus les ellipses sont allongées. On verra que la méthode converge moins vite (pour une initialisation générale) lorsque $\text{cond}(A)$ est grand.

2 Analyse de la convergence (en dimension quelconque)

On a : $x_{k+1} = x_k - \tau \nabla f(x_k)$ et $\nabla f(x_k) = Ax_k - b$. Donc $x_{k+1} - x^* = x_k - x^* - \tau A(x_k - x^*)$ car $Ax^* = b$. $x_{k+1} - x^* = (Id - \tau A)(x_k - x^*)$.

$$\|x_{k+1} - x^*\| \leq \|Id - \tau A\| \|x_k - x^*\|$$

(Par définition de la norme pour les matrices).

Si $\lambda_1(A), \dots, \lambda_d(A)$ sont les valeurs propres de A , alors les valeurs propres de la matrice $Id - \tau A$ sont :


$$1 - \tau \lambda_1(A), \dots, 1 - \tau \lambda_d(A)$$

avec $1 - \tau \lambda_d(A) \leq \dots \leq 1 - \tau \lambda_1(A)$.

En effet, si $v \in \mathbb{R}^d$ est tel que $Av = \lambda_i(A)v$, alors $(Id - \tau A)v = (1 - \tau \lambda_i(A))v$, et si w est tel que $(Id - \tau A)w = (1 - \tau \lambda_i(A))w$, alors $Aw = \lambda_i(A)w$.

Par le résultat énoncé la semaine dernière, comme $Id - \tau A$ est une matrice symétrique, on a :

$$\begin{aligned}
 \|Id - \tau A\| &= \max\{|\lambda_1(Id - \tau A)|, \dots, |\lambda_d(Id - \tau A)|\} \\
 &= \max\{|1 - \tau \lambda_1(A)|, |1 - \tau \lambda_d(A)|\} \\
 &= \max\{1 - \tau \lambda_1(A), \tau \lambda_d(A) - 1\}
 \end{aligned}$$



Intersection : $1 - \tau \lambda_1(A) = \tau \lambda_d(A) - 1 \iff \tau(\lambda_1(A) + \lambda_d(A)) = 2 \iff \tau = \frac{2}{\lambda_1(A) + \lambda_d(A)}$.

Dans ce cas, la valeur maximale est $\frac{\lambda_d(A) - \lambda_1(A)}{\lambda_1(A) + \lambda_d(A)}$.

Pour $\tau > 0$, on a : $\max\{1 - \tau \lambda_1(A), \tau \lambda_d(A) - 1\} < 1 \iff \tau \lambda_d(A) - 1 < 1 \iff \tau < \frac{2}{\lambda_d(A)}$.

Théorème 7: Convergence de la descente de gradient

Soient $A \in \mathbb{R}^{d \times d}$ symétrique définie positive et $b \in \mathbb{R}^d$. La suite des itérées de la méthode de descente de gradient à pas fixe $\tau \in \left]0, \frac{2}{\lambda_d(A)}\right[$ converge linéairement à taux $\alpha := \max\{1 - \tau \lambda_1(A), \tau \lambda_d(A) - 1\}$ vers le point $x^* = A^{-1}b$.

Remarque

- On a aussi vu que la valeur de τ garantissant le meilleur taux de convergence linéaire est $\tau = \frac{2}{\lambda_1(A) + \lambda_d(A)}$. On dit que c'est le **pas fixe optimal** (pourvu que $x_0 \neq x^*$).
- On a toujours $0 < \frac{2}{\lambda_1(A) + \lambda_d(A)} < \frac{2}{\lambda_d(A)}$.
- Pour ce pas fixe optimal, on a calculé que le taux est $\frac{\lambda_d(A) - \lambda_1(A)}{\lambda_d(A) + \lambda_1(A)}$.
- On peut l'écrire en fonction du conditionnement $\text{cond}(A)$:

$$\frac{\lambda_d(A) - \lambda_1(A)}{\lambda_d(A) + \lambda_1(A)} = \frac{\frac{\lambda_d(A)}{\lambda_1(A)} - 1}{\frac{\lambda_d(A)}{\lambda_1(A)} + 1} = \frac{\text{cond}(A) - 1}{\text{cond}(A) + 1}$$

- $\text{cond}(A)$ varie entre 1 et $+\infty$, donc le taux varie bien entre 0 et 1.

XI. Convergence de la méthode de descente de gradient à pas fixe dans le cas général

On cherche à minimiser une fonction $f : \mathbb{R}^d \rightarrow \mathbb{R}$ non nécessairement quadratique.

Théorème 8: Convergence locale

Soit $f \in \mathcal{C}^2(\mathbb{R}^d)$. On suppose que f admette un point de minimum local $x^* \in \mathbb{R}^d$ et que la matrice $\nabla^2 f(x^*)$ soit définie positive.

Alors, pour tout x_0 satisfaisant $\|x_0 - x^*\| \leq \delta$, et pour tout $\tau \in \left]0, \frac{2}{\lambda_d(\nabla^2 f(x^*))}\right[$, la suite $(x_k)_{k \geq 0}$ des itérées de la méthode de descente de gradient à pas fixe τ appliquée à f converge linéairement vers x^* à tout taux strictement supérieur à :

$$\max\{|1 - \tau \lambda_1(\nabla^2 f(x^*))|, |\tau \lambda_d(\nabla^2 f(x^*)) - 1|\}$$

Remarque

Principales différences avec le cas quadratique :

- C'est un résultat local.
- Le taux doit être supérieur à :

$$\max\{|1 - \tau\lambda_1(\nabla^2 f(x^*))|, |\tau\lambda_d(\nabla^2 f(x^*)) - 1|\}$$

Preuve :

On a $x_{k+1} = x_k - \tau \nabla f(x_k)$.

Développement limité : $\nabla f(x_k) = \nabla f(x^*) + \nabla^2 f(\xi_k) \cdot (x_k - x^*)$ pour un certain $\xi_k \in]x^*, x_k[$.

Comme x^* est un point de minimum local, $\nabla f(x^*) = 0$, donc $\nabla f(x_k) = \nabla^2 f(\xi_k) \cdot (x_k - x^*)$.

Et $x_{k+1} = x_k - \tau \nabla^2 f(\xi_k) \cdot (x_k - x^*)$.

$$\begin{aligned} x_{k+1} - x^* &= x_k - x^* - \tau \nabla^2 f(\xi_k) \cdot (x_k - x^*) \\ &= (Id - \tau \nabla^2 f(\xi_k)) \cdot (x_k - x^*) \end{aligned}$$

On en déduit :

$$\|x_{k+1} - x^*\| \leq \|Id - \tau \nabla^2 f(\xi_k)\| \|x_k - x^*\|$$

On a :

$$\begin{aligned} \|Id - \tau \nabla^2 f(\xi_k)\| &= \|(Id - \tau \nabla^2 f(x^*)) + \tau(\nabla^2 f(x^*) - \nabla^2 f(\xi_k))\| \\ &\leq \|Id - \tau \nabla^2 f(x^*)\| + \tau \|\nabla^2 f(x^*) - \nabla^2 f(\xi_k)\| \end{aligned}$$

Soit $\alpha_0 := \max\{1 - \tau\lambda_1(\nabla^2 f(x^*)), \tau\lambda_d(\nabla^2 f(x^*)) - 1\}$.

On a montré : $\|Id - \tau \nabla^2 f(\xi_k)\| \leq \alpha_0 + \tau \|\nabla^2 f(x^*) - \nabla^2 f(\xi_k)\|$.

Soit $\alpha > \alpha_0$. Par continuité de $\nabla^2 f$, il existe $\delta_\alpha > 0$ tel que :

$$\|\xi_k - x^*\| \leq \|x_k - x^*\| < \delta_\alpha \implies \|Id - \tau \nabla^2 f(\xi_k)\| \leq \alpha$$

Si $\|x_0 - x^*\| \leq \delta_\alpha$, alors par récurrence, $\|x_{k+1} - x^*\| \leq \alpha \|x_k - x^*\|$, donc la suite $(x_k)_{k \geq 0}$ converge vers x^* à taux α . $\square$

On peut prendre $\delta = \delta_{\alpha_1}$ pour un certain $\alpha_1 > \alpha_0$. Alors, si $\|x_0 - x^*\| \leq \delta$, alors la suite converge linéairement à taux α_1 .

En particulier, pour tout $\alpha > \alpha_0$, on a $\|x_k - x^*\| \leq \delta_\alpha$ à partir d'un certain rang, donc la suite converge aussi linéairement à taux α .

Que peut-on dire lorsqu'on n'a pas $\nabla^2 f(x^*)$ définie positive, ou lorsque f est moins régulière que $\mathcal{C}^2$?

Que peut-on dire sur la convergence globale ?

Théorème 9: Décroissance stricte

On suppose que $f \in \mathcal{C}^1(\mathbb{R}^d)$, que ∇f est M -lipschitzien pour un certain $M > 0$ et que $\tau \in]0, \frac{1}{M}[$. Alors la suite $(f(x_k))_{k \geq 0}$ est décroissante et strictement décroissante tant qu'elle n'est pas stationnaire.

(plus précisément tant que $\nabla f(x_k) \neq 0$)

Preuve :

Développement limité : $f(x_{k+1}) = f(x_k) + \langle \nabla f(\xi_k), x_{k+1} - x_k \rangle$ pour un certain $\xi_k \in]x_k, x_{k+1}[$

$$f(x_{k+1}) = f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \langle \nabla f(\xi_k) - \nabla f(x_k), x_{k+1} - x_k \rangle$$

où $\langle \nabla f(x_k), x_{k+1} - x_k \rangle = -\tau \|\nabla f(x_k)\|^2$
et

$$\begin{aligned} \langle \nabla f(\xi_k) - \nabla f(x_k), x_{k+1} - x_k \rangle &\leq \|\nabla f(\xi_k) - \nabla f(x_k)\| \|x_{k+1} - x_k\| \\ &\leq M \|\xi_k - x_k\| \|x_{k+1} - x_k\| \\ &\leq M \|x_{k+1} - x_k\|^2 \\ &\leq M \tau^2 \|\nabla f(x_k)\|^2 \end{aligned}$$

On a mq : $f(x_{k+1}) \leq f(x_k) - \tau(1 - \tau M) \|\nabla f(x_k)\|^2$ comme $\tau < \frac{1}{M}$ on a $1 - \tau M > 0$
ce qui donne le résultat attendu. $\square$

Théorème 10: Convergence globale

On se suppose que $f \in \mathcal{C}^1(\mathbb{R}^d)$, que ∇f M -lipschitzien pour un certain $M > 0$, que f est convexe, que f admet un point de minimum $x^* \in \mathbb{R}^d$ et que $\tau \in]0, \frac{1}{2M}]$.

Alors $\forall k \geq 0$, $f(x_k) - f(x^*) \leq \frac{\|x_0 - x^*\|^2}{2\tau k}$

Preuve :

On a déjà établi que : $f(x_{k+1}) \leq f(x_k) - \tau(1 - \tau M) \|\nabla f(x_k)\|^2$

Comme $\tau \leq \frac{1}{2M}$, on a $1 - \tau M \geq \frac{1}{2}$, donc $f(x_{k+1}) \leq f(x_k) - \frac{\tau}{2} \|\nabla f(x_k)\|^2$

Par ailleurs

$$\begin{aligned} \|x_{k+1} - x^*\|^2 &= \|(x_{k+1} - x_k) + (x_k - x^*)\|^2 \\ &= \|x_{k+1} - x_k\|^2 + \|x_k - x^*\|^2 + 2\langle x_{k+1} - x_k, x_k - x^* \rangle \end{aligned}$$

où $\|x_{k+1} - x_k\|^2 = \tau^2 \|\nabla f(x_k)\|^2$

Par $\circledast$, $\|\nabla f(x_k)\|^2 \leq \frac{2}{\tau} (f(x_k) - f(x_{k+1}))$

donc $\|x_{k+1} - x_k\|^2 = \tau^2 \|\nabla f(x_k)\|^2$

$$\leq 2\tau (f(x_k) - f(x_{k+1}))$$

D'autre part, $2\langle x_{k+1} - x_k, x_k - x^* \rangle = -2\tau \langle \nabla f(x_k), x_k - x^* \rangle$

Comme f est convexe, $f(x^*) \geq f(x_k) + \langle \nabla f(x_k), x^* - x_k \rangle$

donc $-2\tau \langle \nabla f(x_k), x_k - x^* \rangle \leq 2\tau (f(x^*) - f(x_k))$

Finalement :

$$\begin{aligned} \|x_{k+1} - x^*\|^2 &\leq \|x_k - x^*\|^2 + 2\tau (f(x_k) - f(x_{k+1})) + 2\tau (f(x^*) - f(x_k)) \\ &= \|x_k - x^*\|^2 - 2\tau (f(x_{k+1}) - f(x^*)) \end{aligned}$$

Somme telescopique :

$$\begin{aligned} \|x_k - x^*\|^2 &\leq \|x_0 - x^*\|^2 - 2\tau \sum_{i=1}^k (f(x_i) - f(x^*)) \\ &\leq \|x_0 - x^*\|^2 - 2\tau k (f(x_k) - f(x^*)). \end{aligned}$$

En particulier,

$$\|x_0 - x^*\|^2 - 2\tau k (f(x_k) - f(x^*)) \geq 0$$

donc $f(x_k) - f(x^*) \leq \frac{\|x_0 - x^*\|^2}{2\tau k}$ $\square$

Remarque

Comparaison avec le resultat du premier theoreme.

Supposons qu'on soit dans le cadre du premier theoreme $f \in \mathcal{C}^2(\mathbb{R}^d)$, x^* point de minimum local tq $\nabla^2 f(x^*)$ définie positive, x_0 suffisamment proche de x^* .

Alors on a la convergence linéaire de $(x_k)_{k \geq 0}$ à un certain taux $\alpha \in]0, 1[$,

$$\|x_k - x^*\| \leq C\alpha^k$$

Pour tout k , on a $f(x_k) = f(x^*) + \underbrace{\langle \nabla f(x^*), x_k - x^* \rangle}_{=0} + \frac{1}{2} \langle x_k - x^*, \nabla^2 f(\xi_k)(x_k - x^*) \rangle$

pour un certain $\xi_k \in]x_k, x^*[$

Supposons que $\exists M > 0$ tq $\|\nabla^2 f(x)\| \leq M$ pour tout $x \in \mathbb{R}^d$

Alors,

$$\begin{aligned} f(x_k) - f(x^*) &\leq \frac{M}{2} \|x_k - x^*\|^2 \\ &\leq \frac{CM}{2} \alpha^{2k} \end{aligned}$$

On a aussi la convergence linéaire de $(f(x_k))_{k \geq 0}$ vers $f(x^*)$

XII. Optimisation sous contrainte

On considère le problème de minimisation de la forme $\min_{x \in X} f(x)$ où $X \subset \mathbb{R}^d$ et $f : X \rightarrow \mathbb{R}$. On peut considérer certains cas particuliers :

- (1) $X = \{x \in \mathbb{R}^d \mid g_1(x) = 0, \dots, g_m(x) = 0\}$ pour certaines fonctions $g_1, \dots, g_m : \mathbb{R}^d \rightarrow \mathbb{R}$.
On parle d'optimisation sous contraintes d'égalité.
- (2) $X = \{x \in \mathbb{R}^d \mid g_1(x) = 0, \dots, g_m(x) = 0, h_1(x) \leq 0, \dots, h_m(x) \leq 0\}$.

Dans ce cours, on considérera le cas des contraintes d'égalité. Ce cas est lié à la notion de **sous-variété** de $\mathbb{R}^d$, qui généralise les courbes et les surfaces dans $\mathbb{R}^d$. On verra que sous certaines hypothèses, un ensemble X de la forme (1) est une sous-variété.

Définition 12: Sous-variété

Un sous-ensemble M de $\mathbb{R}^d$ est une **sous-variété de dimension p** (avec $0 \leq p \leq d$) si, $\forall x \in M$, il existe un voisinage U de x dans $\mathbb{R}^d$, un voisinage V de 0 dans $\mathbb{R}^d$ et un $\mathcal{C}^1$ -difféomorphisme $f : U \rightarrow V$ tel que :

$$f(x) = 0 \quad \text{et} \quad f(M \cap U) = V \cap (\mathbb{R}^p \times \{0_{\mathbb{R}^{d-p}}\})$$

C'est la définition par **redressement**.

Exemple 3: Cercle unité

Considérons le cas $d = 2$ et $M = \mathbb{S}^1$. Soit $a \in \mathbb{S}^1$. Par symétrie/rotation, il suffit de considérer le point $x = (1, 0)$. On peut choisir le voisinage $U = \{(x_1, x_2) \in \mathbb{R}^2, x_1 > 0\}$ et le $\mathcal{C}^1$ -difféomorphisme :

$$f : U \rightarrow V, \quad (x_1, x_2) \mapsto (x_2, x_1^2 + x_2^2 - 1)$$

Remarque

On utilise les termes suivants selon la dimension :

- **Courbe** pour une sous-variété de dimension 1.
- **Surface** pour une sous-variété de dimension 2.
- **Hypersurface** pour une sous-variété de dimension $d - 1$.

1 Immersions et submersions

Définition 13: Immersion et Submersion

Soit $U \subset \mathbb{R}^n$ ouvert, $V \subset \mathbb{R}^m$ ouvert, et $f \in \mathcal{C}^1(U, V)$. Soit $x \in U$.

- On dit que f est une **immersion** en x si l'application linéaire $d_x f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ est injective (soit la matrice jacobienne $J_f(x)$ est de rang n).
- On dit que f est une **submersion** en x si l'application linéaire $d_x f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ est surjective (soit la matrice jacobienne $J_f(x)$ est de rang m).
- On dit que f est une submersion/immersion si c'est une submersion/immersion en tout point $x \in U$

Remarque

Si f est une immersion en x , alors nécessairement $n \leq m$.

Si f est une submersion en x , alors nécessairement $n \geq m$.

Proposition 17: Forme normale locale des immersions

Soit $U \subset \mathbb{R}^n$ ouvert, $f \in \mathcal{C}^1(U, \mathbb{R}^m)$ avec $n \leq m$. On suppose $0 \in U$, $f(0) = 0$ et que f est une immersion en 0.

Alors il existe ϕ un $\mathcal{C}^1$ -difféomorphisme local en 0 tel que :

$$\phi \circ f(x_1, \dots, x_n) = (x_1, \dots, x_n, 0, \dots, 0)$$

Preuve :

On considère la fonction $g : \mathbb{R}^m \rightarrow \mathbb{R}^m$ définie par :

$$(x_1, \dots, x_n, y_{n+1}, \dots, y_m) \mapsto (f_1(x), \dots, f_n(x), f_{n+1}(x) + y_{n+1}, \dots, f_m(x) + y_m)$$

Alors la matrice jacobienne de g en 0 est de la forme :

$$J_g(0) = \left(J_f(0) \middle| \begin{matrix} 0 \\ \vdots \\ 0 \end{matrix} \right)$$

Comme $J_f(0)$ est de rang n , elle admet une sous-matrice inversible de taille $n \times n$. Quitte à faire une permutation des coordonnées, on peut supposer que la matrice :

$$\left(\frac{\partial f_i(x)}{\partial x_j} \right)_{1 \leq i, j \leq n} = \begin{pmatrix} \frac{\partial f_1(x)}{\partial x_1} & \cdots & \frac{\partial f_1(x)}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_n(x)}{\partial x_1} & \cdots & \frac{\partial f_n(x)}{\partial x_n} \end{pmatrix} \text{ est inversible.}$$

Sous cette condition, la matrice $J_g(0)$ est inversible. On conclut en appliquant le théorème d'inversion locale à g : il existe un voisinage V de 0 tel qu'en prenant ϕ comme la réciproque locale de g , on obtient le résultat souhaité. $\square$

Proposition 18: Forme normale locale des submersions

Soit $U \subset \mathbb{R}^n$ ouvert, $f \in \mathcal{C}^1(U, \mathbb{R}^m)$ avec $n \geq m$. On suppose $0 \in U$ et que f est une submersion en 0 avec $f(0) = 0$. Alors il existe ϕ un $\mathcal{C}^1$ -difféomorphisme local en 0 tel que :

$$f \circ \phi(x_1, \dots, x_n) = (x_1, \dots, x_m)$$

Preuve :

On considère la fonction $h : (x_1, \dots, x_n) \mapsto (f_1(x), \dots, f_m(x), x_{m+1}, \dots, x_n)$. La matrice jacobienne $J_h(0)$ est inversible par l'hypothèse de submersion. La preuve se conclut alors comme pour les immersions. $\square$

2 Définition implicite des sous-variétés

Proposition 19: Définition par fonctions implicites

$M \subset \mathbb{R}^d$ est une sous-variété de dimension p si et seulement si pour tout $x \in M$, il existe un voisinage V de x dans $\mathbb{R}^d$ et une fonction $f \in \mathcal{C}^1(V, \mathbb{R}^k)$ (avec $k = d - p$) qui est une submersion en x telle que :

$$M \cap V = f^{-1}(\{0\})$$

Exemple 4: Cercle

Pour $S^1 \subset \mathbb{R}^2$, on peut prendre $U = \mathbb{R}^2 \setminus \{(0,0)\}$ et $f(x_1, x_2) = x_1^2 + x_2^2 - 1$. Le gradient $\nabla f(x) = (2x_1, 2x_2)$ ne s'annule pas sur M , donc f est une submersion.

Idée de la preuve de la Proposition 19 :

Sens direct : Si M est une sous-variété (au sens de la définition par redressement) : Soit $x \in M$. Soit U un voisinage de x , V un voisinage de 0 et $f : U \rightarrow V$ un $\mathcal{C}^1$ -difféomorphisme comme dans la définition par redressement, tel que :

$$f(U \cap M) = V \cap (\mathbb{R}^p \times \{0_{\mathbb{R}^{d-p}}\})$$

Alors on peut considérer la fonction $g : U \rightarrow \mathbb{R}^{d-p}$ définie par les $d - p$ dernières composantes de f :

$$x \mapsto (f_{p+1}(x), \dots, f_d(x))$$

On a bien que $g \in \mathcal{C}^1(U, \mathbb{R}^{d-p})$, que g est une submersion en x (car c'est une projection d'un difféomorphisme) et que $U \cap M = g^{-1}(\{0\})$.

Réciproque : L'argument est similaire. On considère une fonction g comme dans la définition par fonction implicite (submersion). En utilisant la proposition sur la **forme normale locale des submersions**, on peut reconstruire un bon difféomorphisme ϕ qui satisfait la définition par redressement. $\square$

XIII. Retour sur l'équivalence des définitions des sous-variétés

Soit $M \subset \mathbb{R}^d$ et $x \in M$. On dira que M est localement une sous-variété de dimension p au point x si une des deux propriétés équivalentes est vérifiée :

- **Définition par redressement :** Il existe un voisinage U_x de x dans $\mathbb{R}^d$, un voisinage V_x de 0 dans $\mathbb{R}^d$ et un $\mathcal{C}^1$ -difféomorphisme $f_x : U_x \rightarrow V_x$ tel que $f_x(x) = 0$ et $f_x(U_x \cap M) = V_x \cap (\mathbb{R}^p \times \{0\})$.
- **Définition par fonction implicite :** Il existe un voisinage U de x dans $\mathbb{R}^d$ et $f \in \mathcal{C}^1(U, \mathbb{R}^{d-p})$ une submersion en x telle que $U \cap M = f^{-1}(\{0\})$. En particulier $f(x) = 0$.

Alors M est une sous-variété de dimension p si et seulement si elle l'est localement en tout point $x \in M$.

1 Équivalence entre les définitions

On veut montrer qu'on peut construire :

- i) U et f à partir de U_x, V_x, f_x .
- ii) U_x, V_x, f_x à partir de U et f .

Preuve :

- i) Il suffit de choisir $U = U_x$ et $f(y) = ((f_x)_{p+1}(y), \dots, (f_x)_d(y))$.
- ii) Par le résultat sur la forme normale locale des submersions, il existe Φ difféomorphisme local en 0 tel que :

$$f \circ \Phi(u_1, \dots, u_d) = (u_{p+1}, \dots, u_d)$$


On conclut en prenant V_x et U_x tels que Φ soit un difféomorphisme et $f_x = \Phi^{-1}$. □

Proposition 20: Définition par paramétrage

Soit $M \subset \mathbb{R}^d$ et $x \in M$. Alors M est localement au point x une sous-variété de $\mathbb{R}^d$ de dimension p si et seulement s'il existe un voisinage U de x dans $\mathbb{R}^d$, un voisinage V de 0 dans $\mathbb{R}^p$ et $f : V \rightarrow \mathbb{R}^d$ une immersion telle que $f(0) = x$ et f induit un homéomorphisme de V dans $U \cap M$.

Attention : Il ne suffit pas que M soit une image de $\mathbb{R}^p$ (ou d'un ouvert de $\mathbb{R}^p$).

Exemple : (Courbe en 8 / Lemniscate)



Idée de la preuve : Le sens définition par redressement implique la définition par paramétrage est facile. Pour l'autre sens, il faut utiliser le résultat sur la forme normale locale des immersions.

Remarque

- Pour montrer que $M \subset \mathbb{R}^d$ est une sous-variété, on pourra souvent utiliser la définition par fonction implicite ou par immersion.
- Pour montrer que M n'est pas une sous-variété, on pourra souvent contredire la définition par paramétrage.

XIV. Espace tangent

Soit $M \subset \mathbb{R}^d$ une sous-variété de dimension p .

Définition 14: Espace tangent

En tout point $x \in M$, on définit l'espace tangent :

$$T_x M = \{c'(0) \mid \text{il existe } \delta > 0, c \in \mathcal{C}^1(]-\delta, \delta[, M), c(0) = x\}$$

1 Calcul de $T_x M$

Proposition 21: Cas de la définition par redressement

Si U est un voisinage de x , V un voisinage de 0 dans $\mathbb{R}^d$, $f : U \rightarrow V$ un difféomorphisme tel que $f(x) = 0$ et $f(U \cap M) = V \cap (\mathbb{R}^p \times \{0\})$, alors :

$$T_x M = (Jf(x))^{-1}(\mathbb{R}^p \times \{0\})$$

Preuve :

Soit $\delta > 0$ et $c \in \mathcal{C}^1(]-\delta, \delta[, M)$ tel que $c(0) = x$. On peut supposer δ suffisamment petit pour que $c(]-\delta, \delta[) \subset U$. Soit $\tilde{c} : t \mapsto f(c(t))$. Par dérivation des fonctions composées :

$$\tilde{c}'(0) = Jf(c(0)) \cdot c'(0) = Jf(x) \cdot c'(0)$$

Comme $\tilde{c}$ est à valeurs dans le sous-espace vectoriel $\mathbb{R}^p \times \{0\}$ de $\mathbb{R}^d$, on doit avoir $\tilde{c}'(0) \in \mathbb{R}^p \times \{0\}$. Donc $c'(0) \in (Jf(x))^{-1}(\mathbb{R}^p \times \{0\})$ (c'est-à-dire qu'il existe $\tilde{v} \in \mathbb{R}^p \times \{0\}$ tel que $c'(0) = (Jf(x))^{-1}\tilde{v}$). On a donc montré que : $T_x M \subset (Jf(x))^{-1}(\mathbb{R}^p \times \{0\})$.

Montrons l'autre inclusion : Soit $v \in (Jf(x))^{-1}(\mathbb{R}^p \times \{0\})$. Soit $\tilde{v} \in \mathbb{R}^p \times \{0\}$ tel que $v = (Jf(x))^{-1}\tilde{v}$. Soit $\delta > 0$ tel que $]-\delta, \delta[\tilde{v} \subset V$. Considérons les fonctions :

$$\begin{aligned} \tilde{c} :]-\delta, \delta[&\rightarrow \mathbb{R}^p \times \{0\}, & t &\mapsto t\tilde{v} \\ c :]-\delta, \delta[&\rightarrow M, & t &\mapsto f^{-1}(\tilde{c}(t)) = f^{-1}(t\tilde{v}) \end{aligned}$$

Alors $c \in \mathcal{C}^1(]-\delta, \delta[, M)$, $c(0) = x$ et $c'(0) = J(f^{-1})(0) \cdot \tilde{c}'(0) = (Jf(x))^{-1}\tilde{v} = v$. Donc on a bien $(Jf(x))^{-1}(\mathbb{R}^p \times \{0\}) \subset T_x M$. $\square$

Conséquence : $T_x M$ est un sous-espace vectoriel de $\mathbb{R}^d$ de dimension p .

Proposition 22: Cas de la définition par fonction implicite

Soit $x \in M$, U un voisinage de x dans $\mathbb{R}^d$ et $f \in \mathcal{C}^1(U, \mathbb{R}^{d-p})$ une submersion en x telle que $U \cap M = f^{-1}(\{0\})$. Alors :

$$T_x M = \text{Ker}(Jf(x))$$

Preuve :

Montrons d'abord que $T_x M \subset \text{Ker}(Jf(x))$. Soient $\delta > 0$ et $c \in \mathcal{C}^1(]-\delta, \delta[, M)$ tels que $c(0) = x$. On peut supposer δ suffisamment petit pour que $c(]-\delta, \delta[) \subset U$. Soit $g : t \mapsto f(c(t))$. Alors $g(t) = 0$ pour tout $t \in]-\delta, \delta[$ et donc $g'(0) = 0$. Par ailleurs, $g'(0) = Jf(x) \cdot c'(0)$. On en déduit que $c'(0) \in \text{Ker}(Jf(x))$ et donc $T_x M \subset \text{Ker}(Jf(x))$.

Comme $T_x M$ et $\text{Ker}(Jf(x))$ sont deux espaces vectoriels de dimension p , on en déduit que $T_x M = \text{Ker}(Jf(x))$. $\square$

Proposition 23: Cas de la définition par paramétrage

Soit $x \in M$, U un voisinage de x dans $\mathbb{R}^d$, V un voisinage de 0 dans $\mathbb{R}^p$ et $f \in \mathcal{C}^1(V, \mathbb{R}^d)$ une

immersion en 0 telle que $f(0) = x$ et f induit un homéomorphisme de V vers $U \cap M$. Alors :

$$T_x M = \text{Im}(Jf(0))$$

Preuve :

Montrons d'abord que $\text{Im}(Jf(0)) \subset T_x M$. Soit $v \in \text{Im}(Jf(0))$, soit $\tilde{v} \in \mathbb{R}^p$ tel que $v = Jf(0)\tilde{v}$. On peut considérer la fonction (pour $\delta > 0$ suffisamment petit) :

$$c :]-\delta, \delta[\rightarrow M, \quad t \mapsto f(t\tilde{v})$$

Alors $c \in \mathcal{C}^1(]-\delta, \delta[, M)$, $c(0) = x$ et $c'(0) = Jf(0)\tilde{v} = v$. Donc $v \in T_x M$. On a montré que $\text{Im}(Jf(0)) \subset T_x M$. Comme $\text{Im}(Jf(0))$ et $T_x M$ sont deux sous-espaces vectoriels de dimension p , on en déduit que $T_x M = \text{Im}(Jf(0))$. $\square$

XV. Théorème des extrema liés

Théorème 11: Extrema liés

Soient $U \subset \mathbb{R}^d$ un ouvert et $f \in \mathcal{C}^1(U, \mathbb{R})$, $g_1, \dots, g_q \in \mathcal{C}^1(U, \mathbb{R})$. Soit $X = \{x \in U \mid g_1(x) = 0, \dots, g_q(x) = 0\}$.

Si $x_* \in X$ est un point de minimum local (ou de maximum) de la restriction $f|_X$ de f à X , et si $\nabla g_1(x_*), \dots, \nabla g_q(x_*)$ sont linéairement indépendants.

Alors, il existe des réels $\lambda_1, \dots, \lambda_q$ appelés multiplicateurs de Lagrange, tels que :

$$\nabla f(x_*) = \lambda_1 \nabla g_1(x_*) + \dots + \lambda_q \nabla g_q(x_*)$$

Remarque

- Ce résultat s'applique au calcul de solution de problème d'optimisation sous contraintes d'égalité (par exemple dans le cas $U = \mathbb{R}^d$).
- Soit $g : U \rightarrow \mathbb{R}^q$ définie par $g(x) = (g_1(x), \dots, g_q(x))$. Alors la fonction g est une submersion en un point x_* si et seulement si $\nabla g_1(x_*), \dots, \nabla g_q(x_*)$ sont linéairement indépendants.
- Donc, l'hypothèse d'indépendance linéaire garantit que X soit localement une sous-variété au point x_* de dimension $d - q$, par la définition par fonction implicite.
- Souvent on appliquera ce théorème des extrema liés lorsque X est une sous-variété (globalement). Alors l'hypothèse d'indépendance linéaire est satisfaite en tout point de X . Donc, dans ce cas, pour tout point x_* d'extremum local, il existe $\lambda_1, \dots, \lambda_q$ tels que :

$$\begin{aligned} \nabla f(x_*) &= \lambda_1 \nabla g_1(x_*) + \dots + \lambda_q \nabla g_q(x_*) \\ g_1(x_*) &= 0 \\ &\vdots \\ g_q(x_*) &= 0 \end{aligned}$$

C'est un système de $(d + q)$ équations à $(d + q)$ inconnues.

Méthode générale pour résoudre (de façon exacte) le problème d'optimisation sous contraintes (lorsque X est une sous-variété) :

1. Montrer l'existence d'un extremum local.
2. Trouver des candidats à être des extrema locaux en résolvant le système.
3. Parmi les solutions, identifier les extrema locaux.

Preuve :

Sous l'hypothèse du théorème, X est localement une sous-variété au point x_* . Quitte à remplacer U par un voisinage de x_* plus petit, on peut supposer que X est une sous-variété. Soit $v \in T_{x_*} X$. Par définition de $T_{x_*} X$, il existe $\delta > 0$ et $c \in \mathcal{C}^1(]-\delta, \delta[, X)$ tels que $x_* = c(0)$ et $v = c'(0)$.

Comme x_* est un point d'extremum local de $f|_X$, on a que 0 est un point d'extremum local de $f \circ c$. Donc $0 = (f \circ c)'(0) = \langle c'(0), \nabla f(c(0)) \rangle = \langle v, \nabla f(x_*) \rangle$. On a montré que : pour tout $v \in T_{x_*} X$, $\langle v, \nabla f(x_*) \rangle = 0$.

Par ailleurs : $T_{x_*} X = \text{Ker}(Jg(x_*))$. Donc pour tout $v \in \text{Ker}(Jg(x_*))$, $\langle v, \nabla f(x_*) \rangle = 0$. $v \in \text{Ker}(Jg(x_*))$ si et seulement si $\langle v, \nabla g_i(x_*) \rangle = 0$ pour tout $1 \leq i \leq q$.

On en déduit que $\nabla f(x_*) \in \text{Vect}(\nabla g_1(x_*), \dots, \nabla g_q(x_*))$ (algèbre linéaire).

Idée : Si $\nabla f(x_*) \notin \text{Vect}(\nabla g_1(x_*), \dots, \nabla g_q(x_*))$, alors par un procédé d'orthogonalisation de $\nabla f(x_*)$ par rapport à $\nabla g_1(x_*), \dots, \nabla g_q(x_*)$, on trouve $v \in \mathbb{R}^d$ tel que $\langle v, \nabla g_i(x_*) \rangle = 0$ et $\langle v, \nabla f(x_*) \rangle \neq 0$. Ce qui est une contradiction. $\square$

XVI. Retour à l'optimisation libre numérique

1 Retour rapide sur Taylor-Lagrange / Convergence de la méthode à pas fixe

Taylor-Lagrange :

$$f(x+h) = f(x) + dx f(h) + \frac{1}{2} d_x^2 f(h, h) + \dots + \frac{1}{n!} d_x^n f(h, \dots, h) + \frac{1}{(n+1)!} d_\xi^{n+1} f(h, \dots, h)$$

pour un certain $\xi \in]x, x+h[$, si f est de classe $\mathcal{C}^{n+1}$.

C'est vrai si f est à valeurs dans $\mathbb{R}$. Mais si f est à valeurs dans $\mathbb{R}^d$ (Si f est à valeur dans $\mathbb{R}^d$, on a Taylor-Lagrange pour chaque composante mais le ξ peut être différent pour chaque composante). On n'a pas ce problème avec Taylor-Young ou avec Taylor avec reste intégral.

Dans la preuve du résultat de convergence pour la méthode de descente de gradient à pas fixe : $x_{k+1} = x_k - \tau \nabla f(x_k)$. On ne peut en fait pas dire que $\nabla f(x_k) = \nabla f(x_*) + \nabla^2 f(\xi_k)(x_k - x_*)$. Mais, on a :

$$\begin{aligned} \nabla f(x_k) &= \underbrace{\nabla f(x_*)}_{=0} + \int_0^1 \nabla^2 f(x_* + t(x_k - x_*))(x_k - x_*) dt \\ &= \nabla^2 f(x_*)(x_k - x_*) + \int_0^1 (\nabla^2 f(x_* + t(x_k - x_*)) - \nabla^2 f(x_*))(x_k - x_*) dt \end{aligned}$$

Donc :

$$x_{k+1} - x_* = x_k - x_* - \tau \nabla^2 f(x_*)(x_k - x_*) + \tau \int_0^1 \dots$$

On peut conclure comme dans la preuve initiale et en utilisant que :

$$\left\| \int_0^1 (\nabla^2 f(x_* + t(x_k - x_*)) - \nabla^2 f(x_*))(x_k - x_*) dt \right\| \leq \|x_k - x_*\| \sup_{0 \leq t \leq 1} \|\nabla^2 f(x_* + t(x_k - x_*)) - \nabla^2 f(x_*)\|$$

Ceci est contrôlable par la continuité de la matrice Hessienne $\nabla^2 f$.

2 Méthode de descente de gradient à pas optimal

Il s'agit d'une méthode de descente de gradient à pas variable : $x_{k+1} = x_k - \tau_k \nabla f(x_k)$ où on choisit (si possible, sinon la méthode n'est pas bien définie) $\tau_k \geq 0$ tel que :

$$f(x_k - \tau_k \nabla f(x_k)) = \min_{\tau \geq 0} f(x_k - \tau \nabla f(x_k))$$

Autrement dit, τ_k minimise la fonction :

$$g : \tau \mapsto f(x_k - \tau \nabla f(x_k))$$

Idée : Pour trouver τ_k , il faut minimiser une fonction unidimensionnelle. C'est plus facile que de minimiser toute la fonction f . La méthode de descente de gradient à pas optimal est par exemple bien définie si f est de classe $\mathcal{C}^1$ et coercive.

On va étudier cette méthode dans le cas quadratique.

- Dans le cas quadratique on verra que la méthode converge, dans un certain sens, au moins aussi bien que la méthode à pas fixe.
- En pratique, dans le cas quadratique, on utilise plutôt des méthodes encore plus efficaces (par exemple la méthode du gradient conjugué).
- Dans le cas non quadratique souvent, on ne peut pas calculer le pas optimal de façon exacte. Mais on verra des méthodes inspirées de la méthode de descente de gradient à pas optimal.

Cas quadratique : $f(x) = \frac{1}{2}\langle x, Ax \rangle - \langle b, x \rangle$ avec A symétrique définie positive. Calculons τ_k qui minimise $g(\tau) = f(x_k - \tau \nabla f(x_k))$ sur $\mathbb{R}^+$. Supposons que $\nabla f(x_k) \neq 0$, alors $\tau_k > 0$ et $0 = g'(\tau_k)$ (exercice).

XVII. Calcul du pas optimal (cas quadratique)

Soit $g : \mathbb{R}^+ \rightarrow \mathbb{R}$, $\tau \mapsto f(x_k - \tau \nabla f(x_k))$ (où g dépend de k). Si $\nabla f(x_k) = 0$, alors n'importe quel τ convient. Sinon, on doit avoir : $g(\tau_k) = \min_{\tau \geq 0} g(\tau)$, donc $g'(\tau_k) = 0$.

On a :

$$g'(\tau) = -\langle \nabla f(x_k), \nabla f(x_k - \tau \nabla f(x_k)) \rangle$$

Notation : On va définir le résidu $r_k = \nabla f(x_k)$. Ici (dans le cas quadratique), $r_k = Ax_k - b$.

Alors :

$$\begin{aligned} g'(\tau_k) &= -\langle r_k, \nabla f(x_k - \tau_k r_k) \rangle \\ &= -\langle r_k, A(x_k - \tau_k r_k) - b \rangle \\ &= -\langle r_k, Ax_k - b \rangle + \tau_k \langle r_k, Ar_k \rangle \\ &= -\|r_k\|^2 + \tau_k \langle r_k, Ar_k \rangle \end{aligned}$$

Puisque $g'(\tau_k) = 0$, on en déduit :

$$\tau_k = \frac{\|r_k\|^2}{\langle r_k, Ar_k \rangle}$$

1 Vitesse de convergence

Idée de l'analyse : Plutôt que d'étudier la quantité $\|x_{k+1} - x_*\|^2$, on va étudier $\|x_k - x_*\|_A^2 = \langle x_k - x_*, A(x_k - x_*) \rangle$.

On a $x_{k+1} = x_k - \tau_k r_k$. On calcule :

$$\begin{aligned} \langle x_{k+1} - x_*, A(x_{k+1} - x_*) \rangle &= \langle x_k - x_* - \tau_k r_k, A(x_k - x_*) - \tau_k Ar_k \rangle \\ &= \langle x_k - x_*, A(x_k - x_*) \rangle - 2\tau_k \langle r_k, A(x_k - x_*) \rangle + \tau_k^2 \langle r_k, Ar_k \rangle \end{aligned}$$

Or, $\langle r_k, A(x_k - x_*) \rangle = \langle Ax_k - b, A(x_k - x_*) \rangle$. Comme $Ax_* = b$, on a $A(x_k - x_*) = r_k$, donc : $\langle r_k, A(x_k - x_*) \rangle = \|r_k\|^2$.

Donc :

$$\begin{aligned} \langle x_{k+1} - x_*, A(x_{k+1} - x_*) \rangle &= \langle x_k - x_*, A(x_k - x_*) \rangle - 2\frac{\|r_k\|^2}{\langle r_k, Ar_k \rangle} \|r_k\|^2 + \left(\frac{\|r_k\|^2}{\langle r_k, Ar_k \rangle} \right)^2 \langle r_k, Ar_k \rangle \\ &= \langle x_k - x_*, A(x_k - x_*) \rangle - \frac{\|r_k\|^4}{\langle r_k, Ar_k \rangle} \end{aligned}$$

On calcule aussi que :

$$\begin{aligned} \langle x_k - x_*, A(x_k - x_*) \rangle &= \langle A^{-1}A(x_k - x_*), A(x_k - x_*) \rangle \\ &= \langle A^{-1}r_k, r_k \rangle = \langle r_k, A^{-1}r_k \rangle \end{aligned}$$

En factorisant, on obtient :

$$\langle x_{k+1} - x_*, A(x_{k+1} - x_*) \rangle = \langle x_k - x_*, A(x_k - x_*) \rangle \left(1 - \frac{\|r_k\|^4}{\langle r_k, Ar_k \rangle \langle r_k, A^{-1}r_k \rangle} \right)$$

Lemme 1: Inégalité de Kantorovich

Soit $A \in S_d^{++}(\mathbb{R})$. Soient $0 < \lambda_1(A) \leq \dots \leq \lambda_d(A)$ ses valeurs propres. Alors, pour tout $x \in \mathbb{R}^d \setminus \{0\}$:

$$\frac{\|x\|^4}{\langle x, Ax \rangle \langle x, A^{-1}x \rangle} \geq \frac{4\lambda_1(A)\lambda_d(A)}{(\lambda_1(A) + \lambda_d(A))^2}$$

Preuve :

On peut diagonaliser $A : A = QDQ^T$ avec $Q \in SO_d(\mathbb{R})$ et $D = \text{diag}(\lambda_1(A), \dots, \lambda_d(A))$. Quitte à faire le changement de variable $y = Q^T x$, on peut supposer que $A = \text{diag}(\lambda_1(A), \dots, \lambda_d(A))$ et donc $A^{-1} = \text{diag}(\frac{1}{\lambda_1(A)}, \dots, \frac{1}{\lambda_d(A)})$.

Dans ce cas : **1. Montrons que** $\|x\|^4 \leq \langle x, Ax \rangle \langle x, A^{-1}x \rangle$:

$$\begin{aligned} \|x\|^4 &= \left(\sum_{i=1}^d x_i^2 \right)^2 = \left(\sum_{i=1}^d (\sqrt{\lambda_i} x_i) \left(\frac{1}{\sqrt{\lambda_i}} x_i \right) \right)^2 \\ &\leq \left(\sum_{i=1}^d \lambda_i x_i^2 \right) \left(\sum_{i=1}^d \frac{1}{\lambda_i} x_i^2 \right) \quad \text{par Cauchy-Schwarz} \\ &= \langle x, Ax \rangle \langle x, A^{-1}x \rangle \end{aligned}$$

2. Montrons l'autre inégalité : Pour tout $\delta > 0$, on a :

$$\langle x, Ax \rangle \langle x, A^{-1}x \rangle = \left(\sum_{i=1}^d \delta \lambda_i x_i^2 \right) \left(\sum_{i=1}^d \frac{1}{\delta \lambda_i} x_i^2 \right)$$

On va ensuite utiliser l'inégalité arithmético-géométrique : $\forall a, b > 0, \sqrt{ab} \leq \frac{a+b}{2}$. On obtient :

$$\begin{aligned} 2\sqrt{\langle x, Ax \rangle \langle x, A^{-1}x \rangle} &= 2\sqrt{\left(\sum_{i=1}^d \delta \lambda_i x_i^2 \right) \left(\sum_{i=1}^d \frac{1}{\delta \lambda_i} x_i^2 \right)} \\ &\leq \sum_{i=1}^d \delta \lambda_i x_i^2 + \sum_{i=1}^d \frac{1}{\delta \lambda_i} x_i^2 \\ &= \sum_{i=1}^d x_i^2 \left(\delta \lambda_i + \frac{1}{\delta \lambda_i} \right) = \sum_{i=1}^d x_i^2 \phi(\delta \lambda_i) \end{aligned}$$

où $\phi : t \mapsto t + \frac{1}{t}$.

On peut remarquer que la fonction ϕ est convexe sur $\mathbb{R}_+^*$. Donc pour tout $1 \leq i \leq d$, en utilisant que $\delta \lambda_1 \leq \delta \lambda_i \leq \delta \lambda_d$ et la convexité de ϕ , on a :

$$\phi(\delta \lambda_i) \leq \max\{\phi(\delta \lambda_1), \phi(\delta \lambda_d)\}$$

(De façon générale, si Ψ convexe et $t \in [t_a, t_b]$, alors $\Psi(t) \leq \max\{\Psi(t_a), \Psi(t_b)\}$).

Choisissons $\delta = \frac{1}{\sqrt{\lambda_1 \lambda_d}}$ de telle sorte que $\phi(\delta \lambda_1) = \phi(\delta \lambda_d) = \frac{\sqrt{\lambda_1}}{\sqrt{\lambda_d}} + \frac{\sqrt{\lambda_d}}{\sqrt{\lambda_1}}$. Alors $\forall 1 \leq i \leq d$, $\phi(\delta \lambda_i) \leq \frac{\sqrt{\lambda_1}}{\sqrt{\lambda_d}} + \frac{\sqrt{\lambda_d}}{\sqrt{\lambda_1}}$.

Donc :

$$2\sqrt{\langle x, Ax \rangle \langle x, A^{-1}x \rangle} \leq \left(\frac{\sqrt{\lambda_1}}{\sqrt{\lambda_d}} + \frac{\sqrt{\lambda_d}}{\sqrt{\lambda_1}} \right) \sum_{i=1}^d x_i^2 = \left(\frac{\sqrt{\lambda_1}}{\sqrt{\lambda_d}} + \frac{\sqrt{\lambda_d}}{\sqrt{\lambda_1}} \right) \|x\|^2$$

Et en élevant au carré :

$$\begin{aligned} \langle x, Ax \rangle \langle x, A^{-1}x \rangle &\leq \frac{1}{4} \left(\frac{\sqrt{\lambda_1}}{\sqrt{\lambda_d}} + \frac{\sqrt{\lambda_d}}{\sqrt{\lambda_1}} \right)^2 \|x\|^4 \\ &= \frac{1}{4} \left(\frac{\lambda_1 + \lambda_d}{\sqrt{\lambda_1 \lambda_d}} \right)^2 \|x\|^4 = \frac{(\lambda_1 + \lambda_d)^2}{4\lambda_1 \lambda_d} \|x\|^4 \end{aligned}$$

Ce qui prouve le lemme. □

2 Fin de l'analyse de convergence

On avait obtenu :

$$\langle x_{k+1} - x_*, A(x_{k+1} - x_*) \rangle = \langle x_k - x_*, A(x_k - x_*) \rangle \left(1 - \frac{\|r_k\|^4}{\langle r_k, Ar_k \rangle \langle r_k, A^{-1}r_k \rangle} \right)$$

Par l'inégalité de Kantorovich :

$$\begin{aligned} 1 - \frac{\|r_k\|^4}{\langle r_k, Ar_k \rangle \langle r_k, A^{-1}r_k \rangle} &\leq 1 - 4 \frac{\lambda_1(A) \lambda_d(A)}{(\lambda_1(A) + \lambda_d(A))^2} \\ &= \frac{(\lambda_1(A) + \lambda_d(A))^2 - 4\lambda_1(A) \lambda_d(A)}{(\lambda_1(A) + \lambda_d(A))^2} \\ &= \frac{(\lambda_d(A) - \lambda_1(A))^2}{(\lambda_1(A) + \lambda_d(A))^2} \\ &= \left(\frac{\text{Cond}(A) - 1}{\text{Cond}(A) + 1} \right)^2 \end{aligned}$$

Théorème 12: Convergence (Pas Optimal)

On considère $A \in S_d^{++}(\mathbb{R})$, $b \in \mathbb{R}^d$ et $f : x \mapsto \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle$. La descente de gradient à pas optimal converge linéairement à taux $\frac{\text{Cond}(A)-1}{\text{Cond}(A)+1}$.

Remarque

De plus, on a l'estimation précisée :

$$\langle x_k - x_*, A(x_k - x_*) \rangle \leq \left(\frac{\text{Cond}(A) - 1}{\text{Cond}(A) + 1} \right)^{2k} \langle x_0 - x_*, A(x_0 - x_*) \rangle$$

Obtention du taux de convergence linéaire à partir de l'estimation précisée : Par le théorème de Courant-Fischer, on a :

$$\|x_k - x_*\|^2 \leq \frac{1}{\lambda_1(A)} \langle x_k - x_*, A(x_k - x_*) \rangle$$

Soit en combinant :

$$\begin{aligned} \|x_k - x_*\|^2 &\leq \frac{1}{\lambda_1(A)} \left(\frac{\text{Cond}(A) - 1}{\text{Cond}(A) + 1} \right)^{2k} \langle x_0 - x_*, A(x_0 - x_*) \rangle \\ &\leq \frac{\lambda_d(A)}{\lambda_1(A)} \left(\frac{\text{Cond}(A) - 1}{\text{Cond}(A) + 1} \right)^{2k} \|x_0 - x_*\|^2 \end{aligned}$$

En prenant la racine carrée :

$$\|x_k - x_*\| \leq \left(\frac{\text{Cond}(A) - 1}{\text{Cond}(A) + 1} \right)^k \sqrt{\text{Cond}(A)} \|x_0 - x_*\|$$

On trouve bien le taux $\frac{\text{Cond}(A)-1}{\text{Cond}(A)+1}$.

- Le résultat garantit le taux. En pratique, selon l'initialisation x_0 , le taux de convergence est souvent meilleur.
- Néanmoins, il existe des cas (en particulier des initialisations) pour lesquels le taux $\frac{\text{Cond}(A)-1}{\text{Cond}(A)+1}$ est optimal.
- Le résultat montre en fait que la méthode converge au moins aussi bien que la méthode de gradient à pas fixe.

XVIII. Règles d'Armijo et de Wolfe

On cherche à minimiser une fonction f (non nécessairement quadratique) avec une méthode de descente à pas variable. On va s'autoriser à considérer des directions de descente générales.

Définition 15: Direction de descente

Soit $f \in \mathcal{C}^1(\mathbb{R}^d)$ et $x \in \mathbb{R}^d$. On dit que $d \in \mathbb{R}^d$ est une direction de descente pour f au point x si :

$$\langle d, \nabla f(x) \rangle < 0$$

Exemple : $d = -\nabla f(x)$ est une direction de descente pour f en x dès que $\nabla f(x) \neq 0$. f admet des directions de descente en x ssi $\nabla f(x) \neq 0$.

On considère une méthode de la forme : $x_{k+1} = x_k + \tau_k d_k$, où d_k est une direction de descente pour f au point x_k .

Comment choisir τ_k ? Une possibilité est de prendre le pas optimal dans la direction d_k . Mais le pas optimal ne peut pas toujours être calculé efficacement ! On va plutôt essayer de choisir un pas "pas trop grand ni trop petit".

Définition 16: Condition d'Armijo

Soit $f \in \mathcal{C}^1(\mathbb{R}^d)$, $x \in \mathbb{R}^d$, $d \in \mathbb{R}^d$ une direction de descente pour f en x . Soit $\gamma_1 \in]0, 1[$. On dit qu'un pas $\tau \geq 0$ satisfait la condition d'Armijo pour γ_1 (et f, x, d) si :

$$f(x + \tau d) \leq f(x) + \gamma_1 \tau \langle \nabla f(x), d \rangle$$

Intuitivement, la condition d'Armijo demande que le pas ne soit pas trop grand.

Définition 17: Condition de Wolfe

Soient $0 < \gamma_1 < \gamma_2 < 1$. On dit qu'un pas $\tau \geq 0$ satisfait la condition de Wolfe pour γ_1, γ_2 si il satisfait la condition d'Armijo pour γ_1 et si de plus il satisfait la condition de courbure :

$$\langle \nabla f(x + \tau d), d \rangle \geq \gamma_2 \langle \nabla f(x), d \rangle$$

Intuitivement, la condition de courbure demande que le pas ne soit pas trop petit.

Proposition 24: Existence d'un pas de Wolfe

Soient $0 < \gamma_1 < \gamma_2 < 1$. Soit $f \in \mathcal{C}^1(\mathbb{R}^d)$, $x \in \mathbb{R}^d$ et $d \in \mathbb{R}^d$ une direction de descente pour f en x . Si f est bornée inférieurement, alors il existe $\tau > 0$ satisfaisant la condition de Wolfe. (Important : τ dépend typiquement de x).

Preuve :

Pour $\tau > 0$ petit : $f(x + \tau d) = f(x) + \tau \langle \nabla f(x), d \rangle + o(\tau) < f(x) + \gamma_1 \tau \langle \nabla f(x), d \rangle$ car $\gamma_1 < 1$ et $\langle \nabla f(x), d \rangle < 0$. Donc la condition d'Armijo est satisfaite pour τ petit.

On va choisir : $\tau_* = \sup\{\tau > 0 \mid f(x + \tau d) \leq f(x) + \gamma_1 \tau \langle \nabla f(x), d \rangle\}$. Alors $\tau_* \in]0, +\infty]$. On utilise que f est bornée inférieurement. Soit $m = \inf_{x \in \mathbb{R}^d} f(x)$.

Si $f(x + \tau d) \leq f(x) + \gamma_1 \tau \langle \nabla f(x), d \rangle$, alors $m \leq f(x) + \gamma_1 \tau \langle \nabla f(x), d \rangle \iff \gamma_1 \tau \langle \nabla f(x), d \rangle \geq m - f(x) \iff \tau \leq \frac{m - f(x)}{\gamma_1 \langle \nabla f(x), d \rangle}$ (car $\langle \nabla f(x), d \rangle < 0$). Ainsi $\tau_* \leq \frac{m - f(x)}{\gamma_1 \langle \nabla f(x), d \rangle} < +\infty$.

Par continuité, τ_* satisfait la condition d'Armijo avec une égalité : $(*) \quad f(x + \tau_* d) = f(x) + \gamma_1 \tau_* \langle \nabla f(x), d \rangle$.

Condition de courbure : Pour $\epsilon > 0$ petit : $f(x + (\tau_* - \epsilon)d) \leq f(x) + \gamma_1 (\tau_* - \epsilon) \langle \nabla f(x), d \rangle$. En utilisant aussi $(*)$:

$$\begin{aligned} f(x + \tau_* d) - f(x + (\tau_* - \epsilon)d) &\geq \gamma_1 \epsilon \langle \nabla f(x), d \rangle \\ \implies \frac{f(x + \tau_* d) - f(x + (\tau_* - \epsilon)d)}{\epsilon} &\geq \gamma_1 \langle \nabla f(x), d \rangle \end{aligned}$$

En passant à la limite $\epsilon \rightarrow 0$:

$$\langle \nabla f(x + \tau_* d), d \rangle \geq \gamma_1 \langle \nabla f(x), d \rangle > \gamma_2 \langle \nabla f(x), d \rangle$$

(car $\gamma_1 < \gamma_2$ et $\langle \nabla f(x), d \rangle < 0$). Donc la condition de courbure est bien satisfaite en τ_* . $\square$

XIX. Théorème de Zoutendijk

Étudions la convergence de $x_{k+1} = x_k + \tau_k d_k$, où d_k direction de descente en x_k et τ_k satisfait la condition de Wolfe pour $0 < \gamma_1 < \gamma_2 < 1$ indépendants de k .

Estimation de la taille des pas : On va utiliser la condition de courbure. On va aussi supposer que ∇f est L -Lipschitz. Alors : $\langle \nabla f(x_{k+1}), d_k \rangle \geq \gamma_2 \langle \nabla f(x_k), d_k \rangle$, donc :

$$(1 - \gamma_2) \langle \nabla f(x_k), d_k \rangle \leq \langle \nabla f(x_k), d_k \rangle - \langle \nabla f(x_{k+1}), d_k \rangle = \langle \nabla f(x_k) - \nabla f(x_k + \tau_k d_k), d_k \rangle$$

Par Cauchy-Schwarz :

$$\begin{aligned} (1 - \gamma_2) |\langle \nabla f(x_k), d_k \rangle| &\leq \|\nabla f(x_k) - \nabla f(x_k + \tau_k d_k)\| \|d_k\| \\ &\leq L \tau_k \|d_k\|^2 \end{aligned}$$

$$\text{donc } \tau_k \geq \frac{(1 - \gamma_2) |\langle \nabla f(x_k), d_k \rangle|}{L \|d_k\|^2}.$$

Étude de la convergence : On va utiliser cette minoration et aussi la règle d'Armijo :

$$f(x_{k+1}) \leq f(x_k) + \gamma_1 \tau_k \langle \nabla f(x_k), d_k \rangle$$

$$f(x_k) - f(x_{k+1}) \geq \gamma_1 \tau_k |\langle \nabla f(x_k), d_k \rangle| \geq \frac{\gamma_1 (1 - \gamma_2) \langle \nabla f(x_k), d_k \rangle^2}{L \|d_k\|^2}$$

Donc :

$$\frac{\gamma_1 (1 - \gamma_2)}{L} \left(\frac{\langle \nabla f(x_k), d_k \rangle}{\|d_k\|} \right)^2 \leq f(x_k) - f(x_{k+1})$$

Supposons que f soit bornée inférieurement et soit $m := \inf_{x \in \mathbb{R}^d} f(x)$. En sommant :

$$\frac{\gamma_1 (1 - \gamma_2)}{L} \sum_{k=0}^{+\infty} \left(\frac{\langle \nabla f(x_k), d_k \rangle}{\|d_k\|} \right)^2 \leq f(x_0) - m < +\infty$$

On a donc montré :

Théorème 13: Zoutendijk

On suppose que $f \in \mathcal{C}^1(\mathbb{R}^d)$, bornée inférieurement, ∇f L -Lipschitzienne. Soit $x_{k+1} = x_k + \tau_k d_k$ avec d_k direction de descente en x_k et $\tau_k \geq 0$ satisfaisant la règle de Wolfe pour γ_1, γ_2 . Alors :

$$\sum_{k=0}^{+\infty} \left(\frac{\langle \nabla f(x_k), d_k \rangle}{\|d_k\|} \right)^2 < +\infty$$

Remarque

- En particulier, $\frac{\langle \nabla f(x_k), d_k \rangle}{\|d_k\|} \xrightarrow{k \rightarrow +\infty} 0$.
- On peut écrire $\frac{\langle \nabla f(x_k), d_k \rangle}{\|d_k\|} = \frac{\langle \nabla f(x_k), d_k \rangle}{\|\nabla f(x_k)\| \|d_k\|} \|\nabla f(x_k)\| = -\cos(\theta_k) \|\nabla f(x_k)\|$ où θ_k est l'angle entre d_k et $-\nabla f(x_k)$. (Exemple : si $d_k = -\nabla f(x_k)$, $\cos(\theta_k) = 1$).
- Si $\cos(\theta_k)$ est borné inférieurement par $\delta > 0$ (indépendant de k), alors on trouve $\|\nabla f(x_k)\| \xrightarrow{k \rightarrow +\infty} 0$.

XX. Méthode du gradient conjugué

Soient $A \in S_d^{++}(\mathbb{R})$ et $b \in \mathbb{R}^d$. On cherche à minimiser la fonction :

$$f : x \mapsto \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle$$

dont on notera x_* le point de minimum (de façon équivalente, cela revient à résoudre $Ax = b$).

On avait vu la méthode de descente de gradient à pas optimal. On choisit τ_k tel que $f(x_k - \tau_k r_k) = \min_{\tau \in \mathbb{R}} f(x_k - \tau r_k)$ avec $r_k = Ax_k - b$. On avait calculé que $\tau_k = \frac{\|r_k\|^2}{\langle r_k, Ar_k \rangle}$.

1 Généralisation : Directions de descente multiples

On peut essayer de généraliser cette méthode :

- en considérant une direction de descente d_k générale (pas nécessairement $-r_k$).
- en minimisant simultanément selon plusieurs directions de descente $d_{k,1}, \dots, d_{k,n_k}$:

$$x_{k,n_k} = x_k + \sum_{i=1}^{n_k} \tau_{k,i} d_{k,i}$$

où $\tau_{k,1}, \dots, \tau_{k,n_k}$ sont choisis tels que :

$$f \left(x_k + \sum_{i=1}^{n_k} \tau_{k,i} d_{k,i} \right) = \min_{v_1, \dots, v_{n_k} \in \mathbb{R}} f \left(x_k + \sum_{i=1}^{n_k} v_i d_{k,i} \right)$$

Dans ce cas, calculons les pas optimaux. Soit :

$$g : (\tau_1, \dots, \tau_{n_k}) \mapsto f \left(x_k + \sum_{i=1}^{n_k} \tau_i d_{k,i} \right)$$

Alors $(\tau_{k,1}, \dots, \tau_{k,n_k})$ minimise g . Donc, pour tout $1 \leq i \leq n_k$, par la condition d'optimalité d'ordre

1 pour g :

$$\begin{aligned}
0 &= \frac{\partial g}{\partial \tau_i}(\tau_{k,1}, \dots, \tau_{k,n_k}) \\
&= \left\langle d_{k,i}, \nabla f \left(x_k + \sum_{j=1}^{n_k} \tau_{k,j} d_{k,j} \right) \right\rangle \\
&= \left\langle d_{k,i}, A \left(x_k + \sum_{j=1}^{n_k} \tau_{k,j} d_{k,j} \right) - b \right\rangle \\
&= \langle d_{k,i}, r_k \rangle + \sum_{j=1}^{n_k} \tau_{k,j} \langle d_{k,i}, Ad_{k,j} \rangle
\end{aligned}$$

Donc les $\tau_{k,i}$ sont solutions du système linéaire :

$$\begin{pmatrix} \langle d_{k,1}, Ad_{k,1} \rangle & \dots & \langle d_{k,1}, Ad_{k,n_k} \rangle \\ \vdots & \ddots & \vdots \\ \langle d_{k,n_k}, Ad_{k,1} \rangle & \dots & \langle d_{k,n_k}, Ad_{k,n_k} \rangle \end{pmatrix} \begin{pmatrix} \tau_{k,1} \\ \vdots \\ \tau_{k,n_k} \end{pmatrix} = \begin{pmatrix} -\langle d_{k,1}, r_k \rangle \\ \vdots \\ -\langle d_{k,n_k}, r_k \rangle \end{pmatrix}$$

C'est un système linéaire de taille n_k , ce qui est en général coûteux à résoudre si n_k est grand. Cependant, il peut être résolu efficacement dans le cas particulier où pour tout $i \neq j$, $\langle d_{k,i}, Ad_{k,j} \rangle = 0$. On dit que les directions $d_{k,i}$ et $d_{k,j}$ sont **conjuguées par rapport à la matrice A** .

Si les directions $d_{k,i}$ sont deux à deux conjuguées, on trouve :

$$\tau_{k,i} = -\frac{\langle d_{k,i}, r_k \rangle}{\langle d_{k,i}, Ad_{k,i} \rangle}$$

2 Construction de la méthode du gradient conjugué

Dans la méthode du gradient conjugué, on choisit des valeurs particulières de n_k et $d_{k,1}, \dots, d_{k,n_k}$.

- On choisit $n_k = 1$.
- La direction $d_{k,1}$ va dépendre seulement de k (et pas de n_k).

Dans la suite, on notera simplement d_k pour la direction à l'itération k (pour $k \geq 1$). Plus précisément, on choisit :

$$\begin{aligned}
d_1 &= -r_0 \\
d_{k+1} &= -r_k + \frac{\langle d_k, Ar_k \rangle}{\langle d_k, Ad_k \rangle} d_k \quad \text{pour } k \geq 1
\end{aligned}$$

Bien défini si $d_k \neq 0$. Si $d_k = 0$, alors la méthode n'est pas bien définie aux itérations suivantes.

On va montrer que les directions d_i sont deux à deux conjuguées pour A . On vérifie facilement que :

$$\langle d_k, Ad_{k+1} \rangle = \langle d_k, -Ar_k \rangle + \frac{\langle d_k, Ar_k \rangle}{\langle d_k, Ad_k \rangle} \langle d_k, Ad_k \rangle = 0$$

Il reste à montrer que $\langle d_{k+1}, Ad_i \rangle = 0$ pour tout $i < k$. Pour cela, on aura besoin de la définition suivante :

Définition 18: Espace de Krylov

Soient $A \in M_d(\mathbb{R})$ et $b \in \mathbb{R}^d$. Pour tout $i \geq 0$, on définit l'espace de Krylov $\mathcal{K}_i(A, b) \subset \mathbb{R}^d$:

$$\mathcal{K}_i(A, b) = \text{Vect}\{b, Ab, A^2b, \dots, A^{i-1}b\}$$

Remarque

- $\dim(\mathcal{K}_i(A, b)) \leq i$
- $\mathcal{K}_i(A, b) \subset \mathcal{K}_{i+1}(A, b)$
- $A\mathcal{K}_i(A, b) \subset \mathcal{K}_{i+1}(A, b)$

Lemme 2

Tant que d_k est bien défini, $\text{Vect}\{d_1, \dots, d_k\} = \mathcal{K}_k(A, r_0)$ et $x_k \in x_0 + \mathcal{K}_k(A, r_0)$.

Preuve :

Par récurrence :

- **Initialisation :** $d_1 = -r_0$, donc $\text{Vect}\{d_1\} = \text{Vect}\{r_0\} = \mathcal{K}_1(A, r_0)$. $x_1 = x_0 + \tau_1 d_1 \in x_0 + \mathcal{K}_1(A, r_0)$.
- **Hérédité :**

$$x_{k+1} = \underbrace{x_k}_{\in x_0 + \mathcal{K}_k(A, r_0)} + \underbrace{\tau_{k+1} d_{k+1}}_{\in \text{Vect}\{d_{k+1}\}} \in x_0 + \mathcal{K}_{k+1}(A, r_0)$$

$$\text{Avec } r_k = Ax_k - b = A(x_k - x_0) + \underbrace{Ax_0 - b}_{=r_0} \in A\mathcal{K}_k(A, r_0) \oplus \text{Vect}\{r_0\} \subset \mathcal{K}_{k+1}(A, r_0).$$

Donc $d_{k+1} = -r_k + \frac{\langle d_k, Ar_k \rangle}{\langle d_k, Ad_k \rangle} d_k \in \mathcal{K}_{k+1}(A, r_0)$. Donc $\text{Vect}\{d_1, \dots, d_{k+1}\} \subset \mathcal{K}_{k+1}(A, r_0)$, ce qui implique l'égalité par dimension.

□

Par construction, on a en fait $x_k = x_{k,*}$ où $x_{k,*}$ est l'unique point de minimum sur $x_0 + \mathcal{K}_k(A, r_0)$. Ainsi, pour tout $w \in \mathcal{K}_k(A, r_0)$, on a $\langle \nabla f(x_k), w \rangle = 0$ (condition d'optimalité d'ordre 1). On en déduit que, pour tout $i \leq k$, $\langle r_k, d_i \rangle = 0$.

Fin de la preuve que les d_i sont deux à deux conjuguées pour A : Il restait à montrer que $\langle d_{k+1}, Ad_i \rangle = 0$ pour $i < k$.

$$\langle d_{k+1}, Ad_i \rangle = -\underbrace{\langle r_k, Ad_i \rangle}_{=0} + \frac{\langle d_k, Ar_k \rangle}{\langle d_k, Ad_k \rangle} \underbrace{\langle d_k, Ad_i \rangle}_{=0 \text{ par récurrence}} = 0$$

Car $d_i \in \mathcal{K}_i(A, r_0) \subset \mathcal{K}_{k-1}(A, r_0)$, donc $Ad_i \in A\mathcal{K}_i(A, r_0) \subset \mathcal{K}_{i+1}(A, r_0) \subset \mathcal{K}_k(A, r_0)$. Comme $\nabla f(x_k) = r_k$ est orthogonal à $\mathcal{K}_k(A, r_0)$, on a bien $\langle r_k, Ad_i \rangle = 0$. Ces directions sont bien 2 à 2 conjuguées pour A .

On peut alors appliquer la formule précédemment obtenue pour les τ_k . Finalement, on obtient les **relations de récurrence** :

$$\begin{aligned} r_0 &= Ax_0 - b \\ d_1 &= -r_0 \\ \tau_{k+1} &:= -\frac{\langle d_{k+1}, r_k \rangle}{\langle d_{k+1}, Ad_{k+1} \rangle} \\ x_{k+1} &= x_k + \tau_{k+1} d_{k+1} \\ r_{k+1} &= Ax_{k+1} - b \\ d_{k+2} &= -r_{k+1} + \frac{\langle d_{k+1}, Ar_{k+1} \rangle}{\langle d_{k+1}, Ad_{k+1} \rangle} d_{k+1} \end{aligned}$$

3 Convergence de la méthode

Proposition 25: Convergence en dimension finie

La méthode du gradient conjugué converge en d itérations au maximum.

Preuve :

Si $r_k = 0$, alors la méthode converge à un certain rang. Si $r_k \neq 0$, alors $r_k \notin \mathcal{K}_k(A, r_0)$ (sinon, en utilisant que $\langle r_k, w \rangle = 0$ pour tout $w \in \mathcal{K}_k(A, r_0)$, on aurait $r_k = 0$, ce qui est absurde). On en déduit que $d_{k+1} \notin \mathcal{K}_k(A, r_0)$. On en déduit donc que :

$$\dim(\text{Vect}\{d_1, \dots, d_{k+1}\}) = \dim(\text{Vect}\{d_1, \dots, d_k\}) + 1$$

Donc $\dim(\mathcal{K}_{k+1}(A, r_0)) = \dim(\mathcal{K}_k(A, r_0)) + 1$.

Donc si r_k ne s'annule pour aucun $k < d$, on a :

$$\text{Vect}\{d_1, \dots, d_d\} = \mathcal{K}_d(A, r_0) = \mathbb{R}^d$$

Comme on minimise sur tout $\mathbb{R}^d$ et que $\dim(\mathcal{K}_d(A, r_0)) = d$, nécessairement $x_d = x_*$. □